

Hacia la detección temprana de osteoporosis

Araceli Roque Hernández¹

Instituto Nacional de Astrofísica, Óptica y Electrónica, Luis Enrique Erro 1, Sta
María Tonanzintla, 72840 San Andrés Cholula, Pue.
`araceli.roque@inaoe.mx`

Abstract. Este trabajo presenta un método integral para la detección temprana de osteoporosis, enfocándose en la mejora y análisis de imágenes radiográficas de rodilla mediante técnicas avanzadas de procesamiento de imágenes y aprendizaje automático. La metodología adoptada incluye la mejora de la calidad visual de las imágenes usando técnicas como la ecualización adaptativa del histograma por contraste limitado (CLAHE) y la transformada discreta de coseno (DCT), seguido de la extracción de características utilizando el descriptor histograma de gradientes orientados (HOG). Estas características son utilizadas para entrenar modelos de aprendizaje automático y aprendizaje profundo, que clasifican las imágenes en categorías de normal, osteopenia y osteoporosis, con el objetivo de proporcionar una herramienta eficaz para el diagnóstico precoz de la enfermedad. Los resultados demostraron que la combinación de técnicas de procesamiento y modelos de aprendizaje automático avanzados puede mejorar significativamente la precisión del diagnóstico.

Keywords: Procesamiento de imágenes, Osteoporosis, Aprendizaje automático, CLAHE, HOG, Detección temprana

1 Introducción

La osteoporosis es un problema creciente que afecta principalmente a los adultos y se incrementa exponencialmente con la edad. Esta condición se caracteriza por una pérdida de masa ósea y un incremento en el riesgo de sufrir fracturas, lo que conlleva una elevada morbilidad y mortalidad, así como un alto coste sanitario, económico y social [1]. El diagnóstico de osteoporosis debe sospecharse a partir de los 50 años ante cualquier fractura por un traumatismo de baja energía, como una caída, o al descubrir una baja masa ósea. Otros factores de riesgo incluyen menopausia antes de los 40 años, corticoterapia prolongada y predisposición familiar [2].

Además, la osteoporosis puede diagnosticarse antes de que se produzca una fractura mediante la absorciometría dual de rayos X (DXA), que es la técnica de referencia para medir la densidad mineral ósea [2]. Las técnicas de imagenología, incluyendo la proyección de rayos X, la tomografía computarizada (TC), el ultrasonido y la resonancia magnética (RM), son fundamentales para visualizar las estructuras internas y externas del cuerpo humano [3]. Cada una de estas

técnicas tiene ventajas únicas y se aplica en contextos específicos. Por ejemplo, los rayos X se utilizan frecuentemente para detectar fracturas y, en el contexto de la osteoporosis, para calcular la puntuación T.

En el ámbito de la medicina moderna, el manejo y análisis de datos médicos se ha vuelto un componente esencial para el avance en el diagnóstico y tratamiento de enfermedades como la osteoporosis. La extracción efectiva y precisa de información valiosa de estos conjuntos de datos se ha vuelto cada vez más importante. Es aquí donde el aprendizaje automático y la extracción de características desempeñan un papel crucial.

En el contexto de la osteoporosis, la extracción de características de imágenes médicas, como las obtenidas por DXA, permite identificar patrones y señales que pueden no ser evidentes para el ojo humano. Estas características pueden incluir variaciones en la densidad ósea, cambios en la estructura del hueso o incluso sutiles diferencias en la morfología que podrían indicar un riesgo temprano de fractura. El aprendizaje automático aprovecha estas características extraídas para entrenar modelos predictivos que pueden clasificar efectivamente los casos de osteoporosis, predecir el riesgo de fracturas futuras o evaluar la eficacia de diferentes tratamientos[4]. Estos modelos no solo mejoran la precisión del diagnóstico, sino que también personalizan las intervenciones médicas, lo que resulta en una medicina más dirigida y eficiente. Por tanto, la combinación de técnicas avanzadas de extracción de características con algoritmos de aprendizaje automático ofrece grandes promesas para transformar el enfoque tradicional en el diagnóstico y manejo de la osteoporosis.

Este estudio tuvo como objetivo desarrollar un método integral para el análisis de imágenes médicas mediante técnicas avanzadas de procesamiento de imágenes y aprendizaje automático para la detección de osteoporosis en rodilla. La metodología adoptada implica varios pasos, comenzando con el procesamiento detallado de imágenes de rayos X. Posteriormente, las características extraídas se utilizan para alimentar modelos de aprendizaje automático, los cuales están diseñados para clasificar las imágenes en categorías predefinidas. Además, el estudio busca establecer una relación entre los datos extraídos de las imágenes y la información personal de los pacientes, tales como la edad, el género, y la historia médica, entre otros.

2 Trabajos relacionados

Existen varios estudios previos centrados en la detección de la osteoporosis de rodilla. Entre ellos, destaca la investigación realizada por Massatith *et al.* [4], en la que se evaluó la eficacia de modelos de aprendizaje automático, específicamente del algoritmo KNN, para la predicción de osteoporosis utilizando imágenes de rayos X. En su análisis, utilizaron una base de datos compuesta por 2,445 imágenes de rayos X, provenientes de Kaggle y Mendeley. El estudio logró alcanzar una precisión del 78.57% con el modelo KNN.

Abubakar *et al.* [5] implementaron técnicas avanzadas de aprendizaje automático, utilizando redes neuronales convolucionales profundas (CNN) junto

con aprendizaje por transferencia y ajuste fino, para identificar características específicas de la osteoporosis en radiografías de rodilla. Sus investigaciones demostraron que el ajuste fino de los parámetros incrementa significativamente la efectividad de la red CNN VGG-16 en la detección de osteoporosis, logrando una precisión del 88%. Este enfoque destaca el potencial de las técnicas de aprendizaje profundo en la mejora del diagnóstico médico por imágenes.

Wani *et al.* [6] desarrollaron un método basado en la red neuronal convolucional (CNN) para la detección de osteoporosis en radiografías de rodilla, empleando el aprendizaje por transferencia con CNNs preentrenadas como AlexNet, VggNet-16, ResNet. En su estudio, destacaron que la arquitectura preentrenada de AlexNet logró la mayor precisión, alcanzando un 91.1% en el conjunto de datos analizado.

Table 1. Comparativo de diferentes técnicas de procesamiento para clasificación de imágenes con osteoporosis

AUTORES	PROCESAMIENTO	TAREA	MODELO DE ML	PRECISIÓN
Massatith <i>et al.</i> [4]	Escala de grises, normalizado	Clasificación	KNN	78.57
Abubakar <i>et al.</i> [5]	N/A	Clasificación	CNN, VGG16	88.8
Wani <i>et al.</i> [6]	N/A	Clasificación	CNN, VggNet-16, ResNet, AlexNet	91.1

3 Materiales y métodos

3.1 Base de datos

Las imágenes de rayos X de rodilla se recopilaron durante un campamento de Densidad Mineral Ósea (DMO) organizado en el Hospital Unani y Panchkarma, Srinagar, JK, India, y sus sucursales del 21 al 31 de diciembre de 2019. El campamento estuvo abierto para participantes de todos los grupos de edad y géneros de diversas regiones de Cachemira, India. El conjunto de datos incluye imágenes de rayos X y factores clínicos asociados a la osteoporosis. Tras obtener el consentimiento escrito, la DMO se midió con el sistema QUS Sunlight Omnisense 7000S, y posteriormente, los participantes que accedieron se sometieron a una radiografía de rodilla. De los 932 participantes en la prueba de DMO, 240 aceptaron la radiografía, resultando en 37 con DMO normal, 154 osteopénicos y 49 osteoporóticos. El conjunto de datos está disponible en la plataforma Mendeley [7]. Las muestras de radiografías de rodilla de clases normales, osteopénicas y osteoporóticas se muestran en la Figura 1.



Fig. 1. Imágenes de muestra de la base de datos de las tres clases

3.2 Metodología propuesta

Este estudio se centra en la clasificación de la osteoporosis a través del análisis de imágenes de rayos X. El trabajo se estructuró en tres fases: inicialmente, el procesamiento de imágenes para optimizar la calidad y el detalle visual de cada radiografía; seguidamente, la extracción de características, para extraer las características mas significativas de la imagen; y finalmente, la clasificación mediante modelos de aprendizaje automático y aprendizaje profundo. En la figura 2 se muestra el diagrama que se propuso.




Fig. 2. Metodología propuesta

Procesamiento de imágenes El procesamiento de imágenes de rayos X desempeña un papel crucial en su análisis posterior mediante algoritmos de aprendizaje automático. Debido a las limitaciones del equipo, estas imágenes a menudo presentan bajo contraste, lo que dificulta la detección precisa de detalles. Para abordar este problema, es imperativo aplicar técnicas avanzadas de mejora de imagen antes de proceder al análisis automático. Estas técnicas permiten resaltar detalles finos y mejorar la visibilidad de las estructuras óseas, optimizando así la calidad de las imágenes y aumentando la precisión del diagnóstico automatizado.

En el proceso de procesamiento, se utilizaron varias técnicas de mejora, entre ellas el algoritmo de ecualización adaptativa del histograma por contraste limitado (CLAHE), operadores morfológicos, y filtros para eliminar el ruido, como el

filtro de mediana, la transformada discreta de coseno (DCT) y la transformada wavelet discreta (DWT). Para evaluar la eficacia de estas técnicas, se implementaron métricas específicas, incluyendo el error de brillo medio absoluto (AMBE), la relación señal-ruido pico (PSNR) y el error cuadrático medio (MSE). Estas métricas son esenciales para identificar qué técnica ofrece una visualización óptima de los detalles más finos y mejora significativamente la calidad de la imagen.

Técnicas de mejora del contraste basadas en histogramas La ecualización de histograma es un enfoque ampliamente utilizado y sencillo para incrementar el contraste de una imagen antes de llevar a cabo su mejora mediante procesamiento. Esta técnica resulta especialmente beneficiosa cuando los valores de intensidad en la imagen se encuentran restringidos a un rango estrecho.

Mediante la aplicación de esta técnica, se logra una distribución del nivel de intensidad en todo el rango del histograma, lo cual resulta en un aumento del contraste en áreas de la imagen que presentan un contraste más bajo. Esta metodología es especialmente útil en el ámbito médico, como en imágenes térmicas y radiografías de rodilla. La ecualización del histograma permite mejorar la visibilidad de los detalles intrínsecos en las imágenes de rayos X de rodilla. Sin embargo, es importante tener en cuenta que este método puede incrementar el nivel de ruido en la imagen debido a la redistribución del nivel de intensidad.

La ecualización de histograma adaptativa limitada por contraste (CLAHE) es una técnica que mejora la ecualización de histograma convencional. Mientras que la ecualización de histograma transforma toda la imagen, distribuyendo los píxeles en todo el rango y aumentando el nivel de ruido, CLAHE aborda este problema, evita el exceso de brillo en la imagen, lo cual puede resultar en la pérdida de detalles importantes. Inicialmente desarrollado para mejorar el procesamiento de radiografías en la industria naval, ha demostrado ser exitoso también en el campo de la medicina, especialmente para mejorar imágenes de bajo contraste, como los rayos X.

operadores morfológicos El procesamiento morfológico de imágenes es una herramienta poderosa para extraer componentes de una imagen que sean relevantes en la representación y descripción de regiones, como la envolvente convexa, los esqueletos, entre otros. Estas técnicas simplifican las imágenes y preservan las características principales de la forma de los objetos.

La morfología se basa en la teoría de conjuntos y es una técnica útil para representar y definir la forma de una región, incluyendo sus límites. Se utilizan operaciones matemáticas como la reflexión, la traslación y la diferencia en dos conjuntos, denominados A y B. El conjunto A representa un elemento de la imagen, mientras que el conjunto B es un elemento estructurante[?]. Entre los diferentes operadores morfológicos se encuentran la dilatación, la erosión, la apertura, el gradiente, el cierre, el sombrero blanco y el sombrero negro.

La erosión y la dilatación son operaciones opuestas que permiten eliminar y expandir el objeto principal en la imagen, respectivamente. La apertura y el cierre se basan en la secuencia de dilatación y erosión, y ofrecen diferentes efectos sobre la imagen según su orden.

El sombrero de copa (sombrero blanco) extrae las partes brillantes de la imagen sobre un fondo oscuro, mientras que el sombrero inferior (sombrero negro) extrae las características oscuras sobre un fondo claro. Estos operadores son particularmente útiles en imágenes de niveles de gris. Para mejorar el contraste en imágenes de niveles de gris, se recomienda utilizar únicamente los operadores morfológicos de sombrero blanco y sombrero negro.

Para obtener una imagen mejorada utilizando operadores morfológicos, se sigue el siguiente proceso:

- Obtener las transformaciones de sombrero blanco y sombrero negro de la imagen de entrada de forma individual.
- Realizar la operación de adición entre la imagen de entrada y la transformación de sombrero blanco.
- Restar la transformación de sombrero negro de la imagen resultante obtenida en el paso anterior.
- El resultado de esta resta corresponde a la imagen mejorada.

Técnicas de reducción de ruido La reducción de ruido es un procedimiento utilizado para eliminar las imperfecciones en una señal. Normalmente se aplica a señales de audio e imágenes. Al trabajar con imágenes de rayos X, es común encontrar cierto nivel de ruido durante el proceso. En ocasiones, resulta beneficioso reducir o eliminar el ruido de la imagen antes de mejorarla. En esta sección, exploraremos tres tipos de filtros: el filtro mediano, el filtro DCT y el filtro DWT.

Filtro de mediana: El filtro de mediana es una técnica simple y efectiva para reducir el ruido en una imagen. Este filtro se aplica a cada parte de los datos de la imagen. En nuestro experimento, hemos seleccionado un kernel predeterminado de tamaño 5x5 para aplicar la reducción de ruido en la imagen.

Filtro de transformada discreta de coseno (DCT): Es una técnica que descompone una señal en una suma de funciones coseno, de manera similar a la transformada de Fourier que descompone una señal en frecuencias. Es ampliamente utilizado en compresión de datos. En el caso de las imágenes, podemos descomponer la señal en dos dimensiones, tanto en el eje x como en el eje y. El objetivo es descomponer cada componente de la señal de la imagen y localizar las áreas donde se encuentran los valores anómalos (ruido). Luego, al aplicar la función inversa de DCT, obtenemos una imagen que se asemeja a la original pero sin los valores anómalos presentes.

Filtro de la transformada wavelet discreta (DWT): Es una técnica que utiliza una transformada de ondícula para muestrear los datos en intervalos cortos. La DWT ofrece información visual en los dominios temporal y de frecuencia de manera simultánea. Esta transformada wavelet se utiliza comúnmente para reducir el ruido en las imágenes. Al aplicar la DWT, se obtiene una representación de la imagen que permite eliminar o atenuar eficientemente el ruido presente en la misma.

Evaluación de la calidad de la imagen En esta sección se abordan las métricas utilizadas para evaluar el rendimiento de varias técnicas aplicadas a la ima-

gen de entrada. A continuación se analizan diversos parámetros, como el error cuadrático medio (MSE), la relación señal-ruido máxima (PSNR) y el error medio de brillo medio (AMBE). Estas métricas nos proporcionan una medida objetiva de la calidad y precisión de las técnicas aplicadas en comparación con la imagen original.

MSE (Error cuadrático medio): El MSE se calcula como el error cuadrático acumulado entre la imagen original y la imagen mejorada. La MSE viene dada por:

$$MSE = \frac{1}{M \times N} \sum_{m=1}^M \sum_{n=1}^N (I(m, n) - O(m, n))^2$$

Donde,

- M denota el número de filas.
- N denota el número de columnas.

PSNR (Peak-Signal to Noise Ratio): El PSNR es una métrica que calcula la relación señal-ruido máxima en decibelios entre la imagen de entrada y la imagen mejorada. Proporciona una medida de calidad y se deriva del MSE (Error Cuadrático Medio). El PSNR es una evaluación del error máximo presente en la imagen, permitiendo comparar la calidad de la imagen mejorada con la original. El PSNR viene dada por:

$$PSNR = 10 \cdot \log_{10} \left(\frac{R^2}{MSE} \right)$$

Donde,

- MSE denota el error cuadrático medio.
- Para nuestra aplicación, R es 255 (tipo de dato entero sin signo de 8 bits) y denota las fluctuaciones máximas en el tipo de dato de la imagen de entrada.

AMBE (Error de brillo medio): Es una métrica que se obtiene al calcular la diferencia entre la intensidad media de la imagen de entrada y la imagen mejorada. Esta métrica nos proporciona información acerca de la discrepancia promedio en el brillo entre ambas imágenes. Al comparar el AMBE, podemos evaluar cómo la técnica aplicada ha afectado el nivel de brillo general de la imagen. La expresión AMBE es:

$$AMBE = |I(x) - I(y)|$$

Donde,

- $I(x)$ denota la intensidad media de la imagen de entrada.
- $I(y)$ denota la intensidad media de la imagen mejorada.

Extracción y selección de características Para la extracción de características se utilizó, HOG (Histogram of Oriented Gradients) que es un descriptor (también conocido como "extractor de características") ampliamente utilizado en el campo de la visión por computadora y el aprendizaje automático. Aunque se utiliza principalmente en esos contextos, sus aplicaciones también se extienden a la cuantificación y representación de otras características relevantes, como la forma y la textura. El algoritmo de HOG consta de cinco etapas:

1. Normalización de la imagen antes de pasarla al descriptor.
2. Cálculo de los gradientes en las direcciones de los ejes X e Y.
3. Obtención de una votación ponderada por celdas.
4. Normalización del contraste en las celdas superpuestas.
5. Recopilación de todos los histogramas para formar el vector final.

Estas etapas permiten obtener un vector de características representativo que captura la información de las orientaciones de los gradientes presentes en la imagen.

Una vez que se haya completado la extracción de características utilizando HOG, procederemos a una etapa de reducción de estas características. Dado que HOG genera una dimensión considerablemente grande, esta reducción nos permitirá minimizar la redundancia de los datos. Como resultado, lograremos una mejora significativa en la velocidad de extracción de características y clasificación. Para la reducción de características, se implementó una función submodular en combinación con un algoritmo voraz. Este enfoque nos permite seleccionar las características más representativas de las imágenes, basándonos en la información de ganancia por entropía.

4 Desarrollo

La implementación se llevó a cabo en Python tanto para el procesamiento, extracción de características y clasificación.

4.1 Procesamiento de las imágenes

Se aplicó de manera combinada las técnicas mencionadas previamente a la imagen seleccionada. Se probaron las siguientes combinaciones en la imagen:

- Ecualización de histograma adaptativo con contraste limitado (CLAHE)
- CLAHE junto con la reducción de ruido mediante filtro mediano (MF)
- CLAHE seguido de suavizado utilizando operadores morfológicos (MO)
- CLAHE seguido de la técnica de reducción de ruido, basado en la transformada de coseno discreta (DCT).
- CLAHE seguido de la técnica de reducción de ruido, basado en la transformada wavelet discreta (DWT).



Fig. 3. Imagen de la rodilla original sin ningun procesamiento



Fig. 4. Imagen de la rodilla aplicando CLAHE



Fig. 5. Imagen de la rodilla aplicando CLAHE y filtro de mediana

Las técnicas mencionadas se aplicaron a todas las imágenes, las que presentaban osteopenia, osteoporosis y de pacientes normales. En la Figura 3 se presenta la imagen original antes de realizar un procesamiento.

En la Figura 4 se muestra la imagen después de aplicar CLAHE, mientras que en la Figura 5 se presenta la imagen resultante después de aplicar CLAHE y filtro de mediana. Ahora para probar la segunda combinación de CLAHE seguido de un suavizado con las operaciones morfológicas, la imagen resultante se muestra en la figura 6. En la figura 7, se visualiza la imagen resultante después de aplicar CLAHE y DCT. En la figura 8, podemos visualizar la imagen resultante después de aplicar CLAHE y DWT Para evaluar la calidad de la imagen resultante, se



Fig. 6. Imagen de la rodilla aplicando CLAHE y operaciones morfológicas



Fig. 7. Imagen de la rodilla aplicando CLAHE y DCT



Fig. 8. Imagen de la rodilla aplicando CLAHE y DWT

evaluaron métricas de rendimiento como MSE, PSNR y AMBE para cada técnica híbrida por separado. A continuación se muestran los resultados obtenidos de la imagen que elegimos como muestra, tabla 2. Tras analizar los valores en la tabla 2 y realizar una observación visual de las imágenes mejoradas, se determinó que los mejores resultados se obtienen mediante la técnica híbrida CLAHE + DCT para la imagen N1.

En la tabla 3, se muestran las métricas de evaluación de una segunda imagen elegida para mostrar los resultados.

Table 2. Resultados de la evaluación de la imagen N1, al aplicar las diversas técnicas

Técnica	MSE	PSNR	AMBE
CLAHE-MEDIANA	196.806	25.190	3.985
CLAHE-MO	546.358	20.756	3.851
CLAHE-DCT	195.311	25.223	3.556
CLAHE-DWT	206.954	24.972	3.880

Table 3. Resultados de la evaluación de la imagen OP1, al aplicar las diversas técnicas

Técnica	MSE	PSNR	AMBE
CLAHE-MEDIANA	169.520	25.838	0.320
CLAHE-MO	489.128	21.236	0.246
CLAHE-DCT	165.811	25.934	0.027
CLAHE-DWT	175.561	25.686	0.238

Por lo tanto, después de analizar todas las imágenes y los resultados obtenidos, podemos concluir que esta combinación es la más adecuada tanto desde una evaluación cualitativa como cuantitativa.

Una vez finalizado el procesamiento de las imágenes, se procedió a extraer las características pertinentes. Dado que en la detección de la osteoporosis se consideran importantes los detalles finos y la textura de la imagen, se decidió analizar las técnicas de extracción de características texturales. Los descriptores HOG (del inglés Histogram of Oriented Gradients) se basan en la orientación del gradiente en áreas locales de una imagen. El descriptor HOG permite aprovechar de forma eficiente la información.

4.2 Extracción de características

para la extracción de características se implemento el algoritmo HOG de la siguiente forma:

- **Píxeles por celda:** Este parámetro especifica el tamaño de las celdas en las que se divide la imagen para calcular los histogramas de gradientes. se estableció en (16, 16).
- **cells_per_block:** Este parámetro determina el tamaño de los bloques en los que se agrupan las celdas vecinas para realizar la normalización. Se estableció en (1, 1), lo que significa que no se realizó agrupación de celdas y cada celda fue considerada individualmente.
- **orientations:** Este parámetro define el número de orientaciones en las que se divide el rango completo de 360 grados. Se estableció en 9, lo que significa que se calcularon los histogramas de gradientes en 9 direcciones diferentes.




Fig. 9. Matriz de confusión del algoritmo Random Forest.

5 Clasificación

Una vez completados el procesamiento y la extracción de características de las imágenes, se procedió a la clasificación de las mismas en tres categorías: normal, osteopenia y osteoporosis. Para esta tarea, se seleccionaron tres algoritmos de aprendizaje automático: Random Forest, K-Nearest Neighbors (KNN) y Regresión Logística. En la fase de implementación, se dividió el conjunto de datos asignando un 80% para entrenamiento y un 20% para validación.

En el ámbito del aprendizaje profundo, se implementó la técnica de aprendizaje por transferencia, haciendo uso de la red neuronal pre-entrenada VGG19.

6 Resultados

Dentro del conjunto de algoritmos implementados en nuestro estudio, se incluyó el uso de Random Forest. Los resultados derivados de la clasificación realizada con este algoritmo se pueden visualizar en la Tabla 4.

Table 4. Resultados de la clasificación con random forest

Clase	Precisión	Recall	F1-score	Support
0	1.00	0.20	0.33	10
1	0.79	1.00	0.89	31
2	1.00	1.00	1.00	12

En la figura 9, podemos observar la matriz de confusión del algoritmo Random Forest y los resultados obtenidos.

- La clase “Normal” tuvo 2 predicciones correctas y 8 incorrectas como “Osteopenia”.
- La clase “Osteopenia” tuvo 31 predicciones correctas y ninguna incorrecta.
- La clase “Osteoporosis” tuvo 12 predicciones correctas y ninguna incorrecta.

La precisión del modelo propuesto fue de 0.8490566037735849.

Los resultados obtenidos de la clasificación utilizando la red neuronal convolucional VGG19 se presentan a continuación. La matriz de confusión correspondiente se puede apreciar en la Figura 10. Por otro lado, los detalles específicos de la clasificación se encuentran en la Tabla 5. Es importante destacar que la precisión alcanzada por este modelo fue del 90.1%.




Fig. 10. Matriz de confusión de la CNN-Vgg19

Table 5. Resultados de la clasificación con una CNN-Vgg19

Clase	Precisión	Recall	F1-score	Support
0	0.93	0.92	0.92	238
1	0.86	0.86	0.86	111
2	0.89	0.90	0.90	236

7 Discusión

Entre los algoritmos de aprendizaje automático que se pusieron a prueba, Random Forest se destacó como el más eficaz, alcanzando una precisión del 84%. Por otro lado, la red neuronal convolucional que empleó aprendizaje por transferencia a partir de la VGG19 logró una precisión del 90.1%. Sin embargo, aún existen aspectos en los que se pueden realizar mejoras para optimizar su rendimiento.

En cuanto a las investigaciones que guardan relación con el presente estudio, es posible observar que al emplear modelos tradicionales de aprendizaje automático y aplicar una mayor cantidad de técnicas de procesamiento, se pueden obtener resultados más satisfactorios. En la Tabla 6 se presenta una comparativa con investigaciones previas. Al utilizar métodos de aprendizaje automático, se logró una precisión del 84.0%. Sin embargo, en el campo del aprendizaje profundo, aún existen áreas de mejora por explorar.

Table 6. Comparación de trabajos relacionados sobre la clasificación

Procesamiento	Modelo	Precisión (%)
Escala de grises, normalizado	KNN	78.6
Normalización, escalado	CNN, VGG16	88.8
Normalización, escalado	CNN, AlexNet	91.1
CLAHE, DCT (Modelo propuesto)	Random Forest	84.0
CLAHE, DCT (Modelo propuesto)	CNN-Vgg19	90.1

8 Conclusiones

Este trabajo abordó la detección temprana de la osteoporosis a través de un enfoque que integra técnicas avanzadas de procesamiento de imágenes y aprendizaje automático. El trabajo se centró en optimizar la calidad de las radiografías de rodilla mediante diversas técnicas de mejora de imágenes y posteriormente extraer características significativas utilizando el descriptor HOG. Estas características se utilizaron para alimentar modelos de aprendizaje automático y aprendizaje profundo con el objetivo de clasificar las imágenes en categorías de normal, osteopenia y osteoporosis.

Los resultados indican que la combinación de técnicas de mejora de imagen como CLAHE y DCT proporciona mejoras significativas en la calidad visual de las radiografías, lo que facilita una extracción de características más efectiva. En cuanto a la clasificación, los modelos de Random Forest y la red neuronal VGG19 demostraron ser altamente efectivos, alcanzando una precisión considerable en la categorización de los estados de la enfermedad.

Para futuras investigaciones, sería beneficioso experimentar con diversas técnicas de selección de características. Además, explorar otras redes preentrenadas y realizar un ajuste fino podría conducir a resultados más prometedores. Asimismo, contar con un conjunto de datos más extenso podría enriquecer el análisis y mejorar la precisión del modelo.

References

1. R. M. Ortega, A. I. Jiménez Ortega, R. M. Martínez García, E. Cuadrado-Soto, A. Aparicio, and A. M. López-Sobaler, "Nutrición en la prevención y el control de la osteoporosis," *Nutrición Hospitalaria*, vol. 37, no. SPE2, pp. 63–66, 2020.
2. J. Paccou and B. Cortet, "Osteoporosis: generalidades, estrategia diagnóstica," *EMC-Podología*, vol. 25, no. 2, pp. 1–9, 2023.
3. P. Pisani, M. D. Renna, F. Conversano, E. Casciaro, M. Muratore, E. Quarta, M. Di Paola, and S. Casciaro, "Screening and early diagnosis of osteoporosis through x-ray and ultrasound based techniques," *World journal of radiology*, vol. 5, no. 11, p. 398, 2013.
4. J. Massatith, N. Boonnam, and R. Hama, "Osteoporosis prognosis through machine learning analysis of x-ray films," in *2023 27th International Computer Science and Engineering Conference (ICSEC)*. IEEE, 2023, pp. 104–109.

5. U. B. Abubakar, M. M. Boukar, and S. Adeshina, “Evaluation of parameter fine-tuning with transfer learning for osteoporosis classification in knee radiograph,” *International Journal of Advanced Computer Science and Applications*, vol. 13, no. 8, 2022.
6. I. M. Wani and S. Arora, “Osteoporosis diagnosis in knee x-rays by transfer learning based on convolution neural network,” *Multimedia Tools and Applications*, vol. 82, no. 9, pp. 14 193–14 217, 2023.
7. —, “A knee x-ray database for osteoporosis detection,” pp. 1–5, 2021.