

Análisis comparativo de técnicas de procesamiento de imágenes en radiografías para la detección de osteoporosis

ARACELI ROQUE HERNÁNDEZ¹

¹Instituto Nacional de Astrofísica, Óptica y Electrónica, Luis Enrique Erro 1, Sta María Tonanzintla, 72840 San Andrés Cholula, Pue.

ABSTRACT Este estudio aborda la mejora de la calidad de las imágenes radiográficas para la detección y clasificación de condiciones óseas como la osteopenia y la osteoporosis. Se implementaron técnicas avanzadas de procesamiento de imágenes, incluyendo la ecualización de histograma adaptativa por contraste (CLAHE), operadores morfológicos, y filtros de reducción de ruido como la transformada discreta de coseno (DCT) y la transformada wavelet discreta (DWT). Además, se aplicaron técnicas de extracción de características utilizando el descriptor de histogramas de gradientes orientados (HOG) y se emplearon algoritmos de aprendizaje automático para la clasificación. Los resultados demostraron mejoras significativas en la claridad y calidad de las imágenes, facilitando un diagnóstico más preciso y eficiente.

INDEX TERMS Procesamiento de imágenes, HOG, técnicas de reducción de ruido, osteoporosis, aprendizaje automático

I. INTRODUCCIÓN

Las imágenes clínicas desempeñan un papel fundamental en el diagnóstico y seguimiento de diversas condiciones médicas. Estas imágenes se obtienen mediante el uso de dispositivos médicos como la tomografía computarizada (CT), la radiografía y el ultrasonido. Sin embargo, a menudo las imágenes obtenidas a través de estos dispositivos no son lo suficientemente claras y pueden ocultar detalles importantes que son cruciales para realizar un diagnóstico preciso [1].

Los rayos X son especialmente útiles para detectar patologías en estructuras óseas y tejidos blandos, como los músculos. Sin embargo, en las imágenes de diagnóstico por rayos X pueden presentarse artefactos, como puntos oscuros o claros, líneas, empañamiento y partículas. Estos artefactos pueden ser el resultado de diversos factores, como la iluminación de la sala de rayos X, la posición de la placa, la calidad del equipo y el movimiento del paciente durante la captura de la imagen.

La disminución en la calidad de las imágenes puede comprometer la precisión de las predicciones y la detección de patologías realizadas por los modelos de aprendizaje automático. Por lo tanto, es esencial aplicar técnicas de restauración de imágenes para mejorar la claridad y la calidad de estas. La restauración de imágenes puede ayudar a reducir el ruido, mejorar el contraste y resaltar los detalles importantes

en las imágenes. Estas técnicas son especialmente valiosas en el caso de enfermedades como la osteoporosis, donde los detalles finos en las imágenes de rayos X pueden ser cruciales para lograr un diagnóstico temprano y preciso.

A. TRABAJOS RELACIONADOS

En la Tabla 1 se presentan los estudios realizados con la base de datos empleada. Como se puede observar, en la mayoría de los casos no se aplica un procesamiento antes de la clasificación. En el caso del uso de KNN, los autores indican que solo emplearon técnicas de escalado y conversión a escala de grises previo a la implementación del clasificador. En otros casos, se optó por métodos de aprendizaje profundo, obteniendo resultados prometedores. Sin embargo, en el contexto de las imágenes médicas, nos enfrentamos a ciertas limitaciones. La obtención de un volumen significativo de imágenes para entrenamiento es desafiante y, además, se requiere de considerable capacidad de cómputo para procesarlas adecuadamente.

II. METODOLOGÍA

El objetivo de este estudio es mejorar la calidad de las imágenes de radiografías de rodilla en personas con osteoporosis u osteopenia. El trabajo se divide en tres partes fundamentales: procesamiento de las imágenes, extracción

TABLE 1. Comparativo de diferentes técnicas de procesamiento para clasificación de imágenes con osteoporosis

Autores	PROC.	MODELO	PRECISIÓN
Wani <i>et al.</i> [2]	N/A	CNN, AlexNet	91.1
Abubakar <i>et al.</i> [3]	N/A	CNN, VGG16	88.8
Massatith <i>et al.</i> [4]	Escala de grises	KNN	78.57

de características y clasificación de las imágenes según sus etiquetas utilizando modelos de aprendizaje automático.

Las radiografías utilizan rayos X, que son ondas electromagnéticas capaces de atravesar el cuerpo y crear imágenes basadas en la penetración a través de diferentes estructuras, como huesos y tejidos blandos, incluyendo los músculos. Sin embargo, las imágenes de rayos X suelen presentar un bajo contraste y un alto nivel de ruido.

A. BASE DE DATOS

La base de datos utilizada en este estudio se obtuvo de la plataforma Mendeley, la cual fue publicada en el año 2021. Esta base de datos consta de un total de 240 imágenes, que se distribuyen de la siguiente manera: 37 imágenes corresponden a condiciones normales, 154 imágenes muestran osteopenia y 49 imágenes presentan osteoporosis [5]. Además de las imágenes, la base de datos también incluye información clínica relevante, como edad, sexo y los valores de puntuación T obtenidos a través del sistema de ultrasonido cuantitativo.

III. PROCESAMIENTO DE LAS IMÁGENES Y EXTRACCIÓN DE CARACTERÍSTICAS

Para la imagen de entrada se combinaron varias técnicas de mejora de imagen como CLAHE, Operadores morfológicos, se utilizaron filtro de la mediana, transformada discreta de coseno (DCT) y la transformada wavelet discreta (DWT). La imagen mejorada obtenida mediante diversas técnicas se evaluó en función de los parámetros de evaluación de la calidad de la imagen como el error de brillo medio absoluto (AMBE), relación señal-ruido pico (PSNR), el error cuadrático medio (MSE) y el error cuadrático medio (RMSE).

A. TÉCNICAS DE MEJORA DEL CONTRASTE BASADAS EN HISTOGRAMAS

La ecualización de histograma es un enfoque ampliamente utilizado y sencillo para incrementar el contraste de una imagen antes de llevar a cabo su mejora mediante procesamiento. Esta técnica resulta especialmente beneficiosa cuando los valores de intensidad en la imagen se encuentran restringidos a un rango estrecho.

Mediante la aplicación de esta técnica, se logra una distribución del nivel de intensidad en todo el rango del histograma, lo cual resulta en un aumento del contraste en áreas de la imagen que presentan un contraste más bajo. Esta metodología es especialmente útil en el ámbito médico,

como en imágenes térmicas y radiografías de rodilla. La ecualización del histograma permite mejorar la visibilidad de los detalles intrínsecos en las imágenes de rayos X de rodilla. Sin embargo, es importante tener en cuenta que este método puede incrementar el nivel de ruido en la imagen debido a la redistribución del nivel de intensidad.

La ecualización de histograma adaptativa limitada por contraste (CLAHE) es una técnica que mejora la ecualización de histograma convencional. Mientras que la ecualización de histograma transforma toda la imagen, distribuyendo los píxeles en todo el rango y aumentando el nivel de ruido, CLAHE aborda este problema, evita el exceso de brillo en la imagen, lo cual puede resultar en la pérdida de detalles importantes. Inicialmente desarrollado para mejorar el procesamiento de radiografías en la industria naval, ha demostrado ser exitoso también en el campo de la medicina, especialmente para mejorar imágenes de bajo contraste, como los rayos X.

B. OPERADORES MORFOLÓGICOS

El procesamiento morfológico de imágenes es una herramienta poderosa para extraer componentes de una imagen que sean relevantes en la representación y descripción de regiones, como la envolvente convexa, los esqueletos, entre otros. Estas técnicas simplifican las imágenes y preservan las características principales de la forma de los objetos.

La morfología se basa en la teoría de conjuntos y es una técnica útil para representar y definir la forma de una región, incluyendo sus límites. Se utilizan operaciones matemáticas como la reflexión, la traslación y la diferencia en dos conjuntos, denominados A y B. El conjunto A representa un elemento de la imagen, mientras que el conjunto B es un elemento estructurante [6]. Entre los diferentes operadores morfológicos se encuentran la dilatación, la erosión, la apertura, el gradiente, el cierre, el sombrero blanco y el sombrero negro.

La erosión y la dilatación son operaciones opuestas que permiten eliminar y expandir el objeto principal en la imagen, respectivamente. La apertura y el cierre se basan en la secuencia de dilatación y erosión, y ofrecen diferentes efectos sobre la imagen según su orden.

El sombrero de copa (sombrero blanco) extrae las partes brillantes de la imagen sobre un fondo oscuro, mientras que el sombrero inferior (sombrero negro) extrae las características oscuras sobre un fondo claro. Estos operadores son particularmente útiles en imágenes de niveles de gris. Para mejorar el contraste en imágenes de niveles de gris, se recomienda utilizar únicamente los operadores morfológicos de sombrero blanco y sombrero negro.

Para obtener una imagen mejorada utilizando operadores morfológicos, se sigue el siguiente proceso:

- Obtener las transformaciones de sombrero blanco y sombrero negro de la imagen de entrada de forma individual.
- Realizar la operación de adición entre la imagen de entrada y la transformación de sombrero blanco.

- Restar la transformación de sombrero negro de la imagen resultante obtenida en el paso anterior.
- El resultado de esta resta corresponde a la imagen mejorada.

C. TÉCNICAS DE REDUCCIÓN DE RUIDO

La reducción de ruido es un procedimiento utilizado para eliminar las imperfecciones en una señal. Normalmente se aplica a señales de audio e imágenes. Al trabajar con imágenes de rayos X, es común encontrar cierto nivel de ruido durante el proceso. En ocasiones, resulta beneficioso reducir o eliminar el ruido de la imagen antes de mejorarla. En esta sección, exploraremos tres tipos de filtros: el filtro mediano, el filtro DCT y el filtro DWT.

Filtro de mediana: El filtro de mediana es una técnica simple y efectiva para reducir el ruido en una imagen. Este filtro se aplica a cada parte de los datos de la imagen. En nuestro experimento, hemos seleccionado un kernel predeterminado de tamaño 5x5 para aplicar la reducción de ruido en la imagen.

Filtro de transformada discreta de coseno (DCT): Es una técnica que descompone una señal en una suma de funciones coseno, de manera similar a la transformada de Fourier que descompone una señal en frecuencias. Es ampliamente utilizado en compresión de datos. En el caso de las imágenes, podemos descomponer la señal en dos dimensiones, tanto en el eje x como en el eje y. El objetivo es descomponer cada componente de la señal de la imagen y localizar las áreas donde se encuentran los valores anómalos (ruido). Luego, al aplicar la función inversa de DCT, obtenemos una imagen que se asemeja a la original pero sin los valores anómalos presentes.

Filtro de la transformada wavelet discreta(DWT): Es una técnica que utiliza una transformada de ondícula para muestrear los datos en intervalos cortos. La DWT ofrece información visual en los dominios temporal y de frecuencia de manera simultánea. Esta transformada wavelet se utiliza comúnmente para reducir el ruido en las imágenes. Al aplicar la DWT, se obtiene una representación de la imagen que permite eliminar o atenuar eficientemente el ruido presente en la misma.

D. EVALUACIÓN DE LA CALIDAD DE LA IMAGEN

En esta sección se abordan las métricas utilizadas para evaluar el rendimiento de varias técnicas aplicadas a la imagen de entrada. A continuación se analizan diversos parámetros, como el error cuadrático medio (MSE), la relación señal-ruido máxima (PSNR) y el error medio de brillo medio (AMBE). Estas métricas nos proporcionan una medida objetiva de la calidad y precisión de las técnicas aplicadas en comparación con la imagen original.

MSE (Error cuadrático medio): El MSE se calcula como el error cuadrático acumulado entre la imagen original y la

imagen mejorada. La MSE viene dada por:

$$MSE = \frac{1}{M \times N} \sum_{m=1}^M \sum_{n=1}^N (I(m, n) - O(m, n))^2$$

Donde,

- M denota el número de filas.
- N denota el número de columnas.

PSNR (Peak-Signal to Noise Ratio): El PSNR es una métrica que calcula la relación señal-ruido máxima en decibelios entre la imagen de entrada y la imagen mejorada. Proporciona una medida de calidad y se deriva del MSE (Error Cuadrático Medio). El PSNR es una evaluación del error máximo presente en la imagen, permitiendo comparar la calidad de la imagen mejorada con la original. El PSNR viene dada por:

$$PSNR = 10 \cdot \log_{10} \left(\frac{R^2}{MSE} \right)$$

Donde,

- MSE denota el error cuadrático medio.
- Para nuestra aplicación, R es 255 (tipo de dato entero sin signo de 8 bits) y denota las fluctuaciones máximas en el tipo de dato de la imagen de entrada.

AMBE (Error de brillo medio): Es una métrica que se obtiene al calcular la diferencia entre la intensidad media de la imagen de entrada y la imagen mejorada. Esta métrica nos proporciona información acerca de la discrepancia promedio en el brillo entre ambas imágenes. Al comparar el AMBE, podemos evaluar cómo la técnica aplicada ha afectado el nivel de brillo general de la imagen. La expresión AMBE es:

$$AMBE = |I(x) - I(y)|$$

Donde,

- $I(x)$ denota la intensidad media de la imagen de entrada.
- $I(y)$ denota la intensidad media de la imagen mejorada.

E. EXTRACCIÓN DE CARACTERÍSTICAS

HOG (Histogram of Oriented Gradients) es un descriptor (también conocido como "extractor de características") ampliamente utilizado en el campo de la visión por computadora y el aprendizaje automático. Aunque se utiliza principalmente en esos contextos, sus aplicaciones también se extienden a la cuantificación y representación de otras características relevantes, como la forma y la textura. El algoritmo de HOG consta de cinco etapas:

- 1) Normalización de la imagen antes de pasarla al descriptor.
- 2) Cálculo de los gradientes en las direcciones de los ejes X e Y.
- 3) Obtención de una votación ponderada por celdas.
- 4) Normalización del contraste en las celdas superpuestas.
- 5) Recopilación de todos los histogramas para formar el vector final.



FIGURE 1. Imagen de la rodilla original sin ningun procesamiento

Estas etapas permiten obtener un vector de características representativo que captura la información de las orientaciones de los gradientes presentes en la imagen.

IV. RESULTADOS DEL PROCESAMIENTO Y EXTRACCIÓN DE CARACTERÍSTICAS

La implementación se llevó a cabo en Python tanto para el procesamiento y extracción de características.

A. PROCESAMIENTO DE LAS IMÁGENES

Se aplicó de manera combinada las técnicas mencionadas previamente a la imagen seleccionada. Se probaron las siguientes combinaciones en la imagen:

- Ecuilización de histograma adaptativo con contraste limitado (CLAHE)
- CLAHE junto con la reducción de ruido mediante filtro mediano (MF)
- CLAHE seguido de suavizado utilizando operadores morfológicos (MO)
- CLAHE seguido de la técnica de reducción de ruido, basado en la transformada de coseno discreta (DCT).
- CLAHE seguido de la técnica de reducción de ruido, basado en la transformada wavelet discreta (DWT).

Las técnicas mencionadas se aplicaron a todas las imágenes, las que presentaban osteopenia, osteoporosis y de pacientes normales. En la Figura 1 se presenta la imagen original antes de realizar un procesamiento.

En la Figura 2 se muestra la imagen después de aplicar CLAHE, mientras que en la Figura 3 se presenta la imagen resultante después de aplicar CLAHE y filtro de mediana.

Ahora para probar la segunda combinación de CLAHE seguido de un suavizado con las operaciones morfológicas, la imagen resultante se muestra en la figura 4. En la imagen 5, se visualiza la imagen resultante después de aplicar CLAHE y DCT. En la imagen 6, podemos visualizar la imagen resultante después de aplicar CLAHE y DWT. Para evaluar la calidad de la imagen resultante, se evaluaron métricas de rendimiento como MSE, PSNR y AMBE para cada técnica híbrida por separado. A continuación se muestran los resultados obtenidos de la imagen que elegimos como



FIGURE 2. Imagen de la rodilla aplicando CLAHE



FIGURE 3. Imagen de la rodilla aplicando CLAHE y filtro de mediana



FIGURE 4. Imagen de la rodilla aplicando CLAHE y operaciones morfológicas

muestra. Tras analizar los valores en la tabla 2 y realizar una observación visual de las imágenes mejoradas, se determinó que los mejores resultados se obtienen mediante la técnica híbrida CLAHE + DCT para la imagen N1.

En la tabla 3, se muestran las métricas de evaluación de una segunda imagen elegida para mostrar los resultados.

Por lo tanto, después de analizar todas las imágenes y los resultados obtenidos, podemos concluir que esta combinación es la más adecuada tanto desde una evaluación cualitativa como cuantitativa.



FIGURE 5. Imagen de la rodilla aplicando CLAHE y DCT



FIGURE 6. Imagen de la rodilla aplicando CLAHE y DWT

Una vez finalizado el procesamiento de las imágenes, se procedió a extraer las características pertinentes. Dado que en la detección de la osteoporosis se consideran importantes los detalles finos y la textura de la imagen, se decidió analizar las técnicas de extracción de características texturales. Los descriptores HOG (del inglés Histogram of Oriented Gradients) se basan en la orientación del gradiente en áreas locales de

TABLE 2. Resultados de la evaluación de la imagen N1, al aplicar las diversas técnicas

Técnica	MSE	PSNR	AMBE
CLAHE-MEDIANA	196.806	25.190	3.985
CLAHE-MO	546.358	20.756	3.851
CLAHE-DCT	195.311	25.223	3.556
CLAHE-DWT	206.954	24.972	3.880

TABLE 3. Resultados de la evaluación de la imagen OP1, al aplicar las diversas técnicas

Técnica	MSE	PSNR	AMBE
CLAHE-MEDIANA	169.520	25.838	0.320
CLAHE-MO	489.128	21.236	0.246
CLAHE-DCT	165.811	25.934	0.027
CLAHE-DWT	175.561	25.686	0.238

TABLE 4. Resultados de la clasificación con random forest

Clase	Precisión	Recall	F1-score	Support
0	1.00	0.20	0.33	10
1	0.79	1.00	0.89	31
2	1.00	1.00	1.00	12

una imagen. El descriptor HOG permite aprovechar de forma eficiente la información.

B. EXTRACCIÓN DE CARACTERÍSTICAS

para la extracción de características se implementó el algoritmo HOG de la siguiente forma:

- **pixels_per_cell:** Este parámetro especifica el tamaño de las celdas en las que se divide la imagen para calcular los histogramas de gradientes. se estableció en (16, 16) píxeles.
- **cells_per_block:** Este parámetro determina el tamaño de los bloques en los que se agrupan las celdas vecinas para realizar la normalización. Se estableció en (1, 1), lo que significa que no se realizó agrupación de celdas y cada celda fue considerada individualmente.
- **orientations:** Este parámetro define el número de orientaciones en las que se divide el rango completo de 360 grados. Se estableció en 9, lo que significa que se calcularon los histogramas de gradientes en 9 direcciones diferentes.

V. CLASIFICACIÓN

Una vez completados el procesamiento y la extracción de características de las imágenes, se procedió a la clasificación de las mismas en tres categorías: normal, osteopenia y osteoporosis. Para esta tarea, se seleccionaron tres algoritmos de aprendizaje automático: Random Forest, K-Nearest Neighbors (KNN) y Regresión Logística. En la fase de implementación, se dividió el conjunto de datos asignando un 80% para entrenamiento y un 20% para validación.

Entre los algoritmos probados, Random Forest demostró ser el más efectivo, logrando los resultados más prometedores en la clasificación de las imágenes. Los resultados obtenidos del clasificador Random Forest se visualizan en la tabla 4.

En la figura 7, podemos observar la matriz de confusión del algoritmo Random Forest y los resultados obtenidos.

- La clase “Normal” tuvo 2 predicciones correctas y 8 incorrectas como “Osteopenia”.
- La clase “Osteopenia” tuvo 31 predicciones correctas y ninguna incorrecta.
- La clase “Osteoporosis” tuvo 12 predicciones correctas y ninguna incorrecta.

La precisión del modelo propuesto fue de 0.8490566037735849.

VI. CONCLUSIONES

Este trabajo presentó un estudio exhaustivo sobre la aplicación de técnicas de procesamiento de imagen para mejorar




FIGURE 7. Matriz de confusión del algoritmo Random Forest.

la calidad de las radiografías en la detección y clasificación de la osteoporosis. A través de una serie de experimento diseñados, se demostró la efectividad de las técnicas de mejora de contraste y reducción de ruido, así como el valor de los descriptores de características HOG en la mejora significativa de la calidad de las imágenes. La precisión alcanzada en la clasificación con algoritmos de aprendizaje automático y la mejora en la calidad de las imágenes resaltan la importancia de las técnicas de procesamiento previo a la implementación de cualquier modelo de aprendizaje automático.

Las futuras líneas de investigación podrían explorar la integración de estas técnicas con enfoques de aprendizaje profundo y la aplicación de este marco a un conjunto de datos más amplio, lo que podría mejorar aún más la capacidad de diagnóstico y detección de la osteoporosis. El enfoque propuesto tiene el potencial de ser extendido a otras aplicaciones médicas, donde la claridad de las imágenes es de suma importancia.

REFERENCES

[1] M. Sharma and D. Kumar, "Comparative analysis of image enhancement techniques for chest x-ray images," pp. 130–135, 2022.

[2] I. M. Wani and S. Arora, "Osteoporosis diagnosis in knee x-rays by transfer learning based on convolution neural network," *Multimedia Tools and Applications*, vol. 82, no. 9, pp. 14 193–14 217, 2023.

[3] U. B. Abubakar, M. M. Boukar, and S. Adeshina, "Evaluation of parameter fine-tuning with transfer learning for osteoporosis classification in knee radiograph," *International Journal of Advanced Computer Science and Applications*, vol. 13, no. 8, 2022.

[4] J. Massatith, N. Boonnam, and R. Hama, "Osteoporosis prognosis through machine learning analysis of x-ray films," pp. 104–109, 2023.

[5] I. M. Wani and S. Arora, "A knee x-ray database for osteoporosis detection," pp. 1–5, 2021.

[6] W. Rui and W. Guoyu, "Medical x-ray image enhancement method based on tv-homomorphic filter," pp. 315–318, 2017.