

Detección de osteoporosis a través de imágenes de rayos X

Araceli Roque Hernández¹

Instituto Nacional de Astrofísica, Óptica y Electrónica, Luis Enrique Erro 1, Sta
María Tonanzintla, 72840 San Andrés Cholula, Pue.
`araceli.roque@inaoe.mx`

Abstract. En este estudio, abordamos el diagnóstico precoz de la osteoporosis mediante técnicas de procesamiento de imágenes y aprendizaje automático. Utilizamos métodos de extracción de características, como el Histograma de Gradientes Orientados (HOG), y aplicamos técnicas de selección de características como ANOVA y LASSO para optimizar el conjunto de datos antes de la clasificación. Nuestros modelos de clasificación incluyen Random Forest, Regresión Logística y K-Vecinos Más Cercanos (KNN) para clasificar las condiciones osteopénicas y osteoporóticas en imágenes de rayos X.

Keywords: Osteoporosis · Aprendizaje automático · Extracción de características · Procesamiento de imágenes · Selección de características.

1 Introducción

La osteoporosis es un problema creciente que afecta principalmente a los adultos y se incrementa exponencialmente con la edad. Esta condición se caracteriza por una pérdida de masa ósea y un incremento en el riesgo de sufrir fracturas, lo que conlleva una elevada morbilidad y mortalidad, así como un alto coste sanitario, económico y social [1]. La osteoporosis puede diagnosticarse antes de que se produzca una fractura mediante la absorciometría dual de rayos X (DXA), que es la técnica de referencia para medir la densidad mineral ósea [2]. Las técnicas de imagenología, incluyendo la proyección de rayos X, la tomografía computarizada (TC), el ultrasonido y la resonancia magnética (RM), son fundamentales para visualizar las estructuras internas y externas del cuerpo humano [3]. Cada una de estas técnicas tiene ventajas únicas y se aplica en contextos específicos. Por ejemplo, los rayos X se utilizan frecuentemente para detectar fracturas y, en el contexto de la osteoporosis, para calcular la puntuación T.

En el ámbito de la medicina moderna, el manejo y análisis de datos médicos se ha vuelto un componente esencial para el avance en el diagnóstico y tratamiento de enfermedades como la osteoporosis. La extracción y selección efectiva de información valiosa de estos conjuntos de datos se ha vuelto cada vez más importante. Es aquí donde el aprendizaje automático y la extracción de características desempeñan un papel crucial. En el contexto de la osteoporosis, la extracción de características de imágenes médicas, como las obtenidas por

DXA, permite identificar patrones y señales que pueden no ser evidentes para el ojo humano. Estas características pueden incluir variaciones en la densidad ósea, cambios en la estructura del hueso o incluso sutiles diferencias en la morfología que podrían indicar un riesgo temprano de fractura. El aprendizaje automático aprovecha estas características extraídas para entrenar modelos predictivos que pueden clasificar efectivamente los casos de osteoporosis, predecir el riesgo de fracturas futuras o evaluar la eficacia de diferentes tratamientos[4]. Estos modelos no solo mejoran la precisión del diagnóstico, sino que también personalizan las intervenciones médicas, lo que resulta en una medicina más dirigida y eficiente.

Por lo tanto, en este estudio se ha propuesto un método de extracción de características utilizando el Histograma de Gradientes Orientados (HOG) para obtener un conjunto óptimo de características. Adicionalmente, se implementó una reducción de dimensionalidad a través de técnicas de selección de características de filtro, como ANOVA, y métodos embebidos, como LASSO, para minimizar el número de atributos redundantes. Finalmente, las características resultantes se han clasificado utilizando tres métodos: bosque aleatorio, regresión logística y k-vecinos más cercanos (KNN).

2 Trabajos relacionados

Existen varios estudios previos centrados en la detección de la osteoporosis de rodilla. Entre ellos, destaca la investigación realizada por Massatith *et al.* [4], en la que se evaluó la eficacia de modelos de aprendizaje automático, específicamente del algoritmo KNN ($k=11$), para la predicción de osteoporosis utilizando imágenes de rayos X. En su estudio utilizaron una base de datos provenientes mendeley. El estudio logró alcanzar una precisión del 78.57% con el modelo KNN.

Abubakar *et al.* [5] implementaron técnicas avanzadas de aprendizaje automático, utilizando redes neuronales convolucionales (CNN) junto con aprendizaje por transferencia y ajuste fino, para identificar características específicas de la osteoporosis en radiografías de rodilla. Sus investigaciones demostraron que el ajuste fino de los parámetros incrementa significativamente la efectividad de la red CNN VGG-16 en la detección de osteoporosis, logrando una precisión del 88%. Este enfoque destaca el potencial de las técnicas de aprendizaje profundo en la mejora del diagnóstico médico por imágenes.

Wani *et al.* [6] desarrollaron un método basado en la red neuronal convolucional (CNN) para la detección de osteoporosis en radiografías de rodilla, empleando el aprendizaje por transferencia con CNNs preentrenadas como AlexNet, VggNet-16, ResNet. En su estudio, destacaron que la arquitectura preentrenada de AlexNet logró la mayor precisión, alcanzando un 91.1% en el conjunto de datos analizado. En la tabla 1

3 Metodología

En esta sección, detallaremos las técnicas de procesamiento de imágenes, extracción y selección de características, así como los métodos de aprendizaje

Table 1. Comparativo de diferentes técnicas de procesamiento para clasificación de imágenes de rayos X con osteoporosis

AUTORES	PROCESAMIENTO	TAREA	MODELO DE ML	PRECISIÓN
Massatith <i>et al.</i> [4]	Escala de grises, normalizado	Clasificación	KNN	78.57
Abubakar <i>et al.</i> [5]	N/A	Clasificación	CNN, VGG16	88.8
Wani <i>et al.</i> [6]	N/A	Clasificación	CNN, VggNet-16, ResNet, AlexNet	91.1

automático que hemos implementado en nuestro estudio. Comenzamos con un procesamiento preliminar de las imágenes para mejorar el contraste antes de la extracción de características. Para ello, empleamos el método de Histograma de Gradientes Orientados (HOG). A continuación, aplicamos dos técnicas de reducción de características para minimizar la redundancia y mejorar la eficacia del análisis. Finalmente, utilizamos tres distintos modelos de aprendizaje automático para clasificar efectivamente las imágenes ya procesadas (Figura 1).




Fig. 1. Modelo propuesto

3.1 Procesamiento de imágenes

El procesamiento de imágenes de rayos X desempeña un papel crucial en su análisis posterior mediante algoritmos de aprendizaje automático. Debido a las limitaciones del equipo, estas imágenes a menudo presentan bajo contraste, lo que dificulta la detección precisa de detalles. Para abordar este problema, es imperativo aplicar técnicas avanzadas de mejora de imagen antes de proceder al análisis automático. Estas técnicas permiten resaltar detalles finos y mejorar la visibilidad de las estructuras óseas, optimizando así la calidad de las imágenes y aumentando la precisión del diagnóstico automatizado. Se utilizaron

varias técnicas de mejora, entre ellas el algoritmo de ecualización adaptativa del histograma por contraste limitado (CLAHE), operadores morfológicos, y filtros para eliminar el ruido, como el filtro de mediana, la transformada discreta de coseno (DCT) y la transformada wavelet discreta (DWT). Para evaluar la eficacia de estas técnicas, se implementaron métricas específicas, incluyendo el error de brillo medio absoluto (AMBE), la relación señal-ruido pico (PSNR) y el error cuadrático medio (MSE). Estas métricas son esenciales para identificar qué técnica ofrece una visualización óptima de los detalles más finos y mejora significativamente la calidad de la imagen.

Técnicas de mejora del contraste basadas en histogramas La ecualización de histograma es un enfoque ampliamente utilizado y sencillo para incrementar el contraste de una imagen antes de llevar a cabo su mejora mediante procesamiento. Esta técnica resulta especialmente beneficiosa cuando los valores de intensidad en la imagen se encuentran restringidos a un rango estrecho. Mediante la aplicación de esta técnica, se logra una distribución del nivel de intensidad en todo el rango del histograma, lo cual resulta en un aumento del contraste en áreas de la imagen que presentan un contraste más bajo. Esta metodología es especialmente útil en el ámbito médico, como en imágenes térmicas y radiografías de rodilla. La ecualización del histograma permite mejorar la visibilidad de los detalles intrínsecos en las imágenes de rayos X de rodilla. Sin embargo, es importante tener en cuenta que este método puede incrementar el nivel de ruido en la imagen debido a la redistribución del nivel de intensidad. La ecualización de histograma adaptativa limitada por contraste (CLAHE) es una técnica que mejora la ecualización de histograma convencional. Mientras que la ecualización de histograma transforma toda la imagen, distribuyendo los píxeles en todo el rango y aumentando el nivel de ruido, CLAHE aborda este problema, evita el exceso de brillo en la imagen, lo cual puede resultar en la pérdida de detalles importantes. Inicialmente desarrollado para mejorar el procesamiento de radiografías en la industria naval, ha demostrado ser exitoso también en el campo de la medicina, especialmente para mejorar imágenes de bajo contraste, como los rayos X.

Operadores morfológicos El procesamiento morfológico de imágenes es una herramienta poderosa para extraer componentes de una imagen que sean relevantes en la representación y descripción de regiones, como la envolvente convexa, los esqueletos, entre otros. Estas técnicas simplifican las imágenes y preservan las características principales de la forma de los objetos. La morfología se basa en la teoría de conjuntos y es una técnica útil para representar y definir la forma de una región, incluyendo sus límites. Se utilizan operaciones matemáticas como la reflexión, la traslación y la diferencia en dos conjuntos, denominados A y B. El conjunto A representa un elemento de la imagen, mientras que el conjunto B es un elemento estructurante[?]. Entre los diferentes operadores morfológicos se encuentran la dilatación, la erosión, la apertura, el gradiente, el cierre, el sombrero blanco y el sombrero negro. El sombrero de copa (sombrero blanco)

extrae las partes brillantes de la imagen sobre un fondo oscuro, mientras que el sombrero inferior (sombrero negro) extrae las características oscuras sobre un fondo claro. Estos operadores son particularmente útiles en imágenes de niveles de gris. Para mejorar el contraste en imágenes de niveles de gris, se recomienda utilizar únicamente los operadores morfológicos de sombrero blanco y sombrero negro.

Para obtener una imagen mejorada utilizando operadores morfológicos, se sigue el siguiente proceso:

- Obtener las transformaciones de sombrero blanco y sombrero negro de la imagen de entrada de forma individual.
- Realizar la operación de adición entre la imagen de entrada y la transformación de sombrero blanco.
- Restar la transformación de sombrero negro de la imagen resultante obtenida en el paso anterior.
- El resultado de esta resta corresponde a la imagen mejorada.

Técnicas de reducción de ruido La reducción de ruido es un procedimiento utilizado para eliminar las imperfecciones en una señal. Normalmente se aplica a señales de audio e imágenes. Al trabajar con imágenes de rayos X, es común encontrar cierto nivel de ruido durante el proceso. En ocasiones, resulta beneficioso reducir o eliminar el ruido de la imagen antes de mejorarla. En esta sección, exploraremos tres tipos de filtros: el filtro mediano, el filtro DCT y el filtro DWT.

Filtro de mediana : El filtro de mediana es una técnica simple y efectiva para reducir el ruido en una imagen. Este filtro se aplica a cada parte de los datos de la imagen. En nuestro experimento, hemos seleccionado un kernel predeterminado de tamaño 5x5 para aplicar la reducción de ruido en la imagen.

Filtro de transformada discreta de coseno (DCT) : Es una técnica que descompone una señal en una suma de funciones coseno, de manera similar a la transformada de Fourier que descompone una señal en frecuencias. Es ampliamente utilizado en compresión de datos. En el caso de las imágenes, podemos descomponer la señal en dos dimensiones, tanto en el eje x como en el eje y. El objetivo es descomponer cada componente de la señal de la imagen y localizar las áreas donde se encuentran los valores anómalos (ruido). Luego, al aplicar la función inversa de DCT, obtenemos una imagen que se asemeja a la original pero sin los valores anómalos presentes.

Filtro de la transformada wavelet discreta (DWT) : Es una técnica que utiliza una transformada de ondícula para muestrear los datos en intervalos cortos. La DWT ofrece información visual en los dominios temporal y de frecuencia de manera simultánea. Esta transformada wavelet se utiliza comúnmente para reducir el

ruido en las imágenes. Al aplicar la DWT, se obtiene una representación de la imagen que permite eliminar o atenuar eficientemente el ruido presente en la misma.

Evaluación de la calidad de la imagen Las métricas utilizadas para evaluar el rendimiento de varias técnicas aplicadas a la imagen de entrada se utilizó el error cuadrático medio (MSE), la relación señal-ruido máxima (PSNR) y el error medio de brillo medio (AMBE). Estas métricas nos proporcionan una medida objetiva de la calidad y precisión de las técnicas aplicadas en comparación con la imagen original.

MSE (Error cuadrático medio) : El MSE se calcula como el error cuadrático acumulado entre la imagen original y la imagen mejorada. La MSE viene dada por:

$$MSE = \frac{1}{M \times N} \sum_{m=1}^M \sum_{n=1}^N (I(m, n) - O(m, n))^2$$

Donde,

- M denota el número de filas.
- N denota el número de columnas.

PSNR (Peak-Signal to Noise Ratio) : El PSNR es una métrica que calcula la relación señal-ruido máxima en decibelios entre la imagen de entrada y la imagen mejorada. Proporciona una medida de calidad y se deriva del MSE (Error Cuadrático Medio). El PSNR es una evaluación del error máximo presente en la imagen, permitiendo comparar la calidad de la imagen mejorada con la original. El PSNR viene dada por:

$$PSNR = 10 \cdot \log_{10} \left(\frac{R^2}{MSE} \right)$$

Donde,

- MSE denota el error cuadrático medio.
- Para nuestra aplicación, R es 255 (tipo de dato entero sin signo de 8 bits) y denota las fluctuaciones máximas en el tipo de dato de la imagen de entrada.

AMBE (Error de brillo medio) : Es una métrica que se obtiene al calcular la diferencia entre la intensidad media de la imagen de entrada y la imagen mejorada. Esta métrica nos proporciona información acerca de la discrepancia promedio en el brillo entre ambas imágenes. Al comparar el AMBE, podemos evaluar cómo la técnica aplicada ha afectado el nivel de brillo general de la imagen. La expresión AMBE es:

$$AMBE = |I(x) - I(y)|$$

Donde,

- $I(x)$ denota la intensidad media de la imagen de entrada.
- $I(y)$ denota la intensidad media de la imagen mejorada.

3.2 Extracción de características

Para la extracción de características se utilizo, HOG que es un descriptor ampliamente utilizado en el campo de la visión por computadora y el aprendizaje automático. Aunque se utiliza principalmente en esos contextos, sus aplicaciones también se extienden a la cuantificación y representación de otras características relevantes, como la forma y la textura. El algoritmo de HOG consta de cinco etapas:

1. Normalización de la imagen antes de pasarla al descriptor.
2. Cálculo de los gradientes en las direcciones de los ejes X e Y.
3. Obtención de una votación ponderada por celdas.
4. Normalización del contraste en las celdas superpuestas.
5. Recopilación de todos los histogramas para formar el vector final.

Estas etapas permiten obtener un vector de características representativo que captura la información de las orientaciones de los gradientes presentes en la imagen.

3.3 Selección de características

La selección de características es importante en el análisis de datos, dado que no todos aportan información relevante. Un número excesivo de estos puede complicar el proceso de clasificación, alargar los tiempos de procesamiento y dificultar la identificación de patrones significativos. Por ello, es fundamental elegir únicamente aquellas características relevantes, lo que contribuye a una mayor precisión en los resultados de clasificación y optimiza la carga computacional. Emplear métodos efectivos para esta selección es clave para simplificar el modelo y mejorar o mantener su precisión.

El método de filtrado evalúa las características utilizando criterios estadísticos, como el Análisis de Varianza (ANOVA), para determinar la importancia de cada una en relación con la variable objetivo. En este enfoque, se seleccionan aquellas características que demuestran tener una influencia significativa sobre la variable dependiente, basándose en sus puntuaciones obtenidas mediante el ANOVA. Al emplear este método de filtrado no solo simplifica el modelo al eliminar características irrelevantes, sino que también mejora la eficiencia del proceso de clasificación al concentrarse en los atributos más determinantes.

Los métodos embebidos representan una categoría de técnicas para la selección de características directamente dentro del proceso de entrenamiento del modelo. Estos métodos optimizan la selección de características como una parte intrínseca del proceso de aprendizaje, lo que permite que la selección y la modelación ocurran simultáneamente. LASSO (Least Absolute Shrinkage and Selection Operator) es una técnica de regresión regularizada que pertenece a los

métodos embebidos de análisis de regresión. Este método realiza simultáneamente la selección de variables y la regularización para mejorar tanto la precisión como la interpretabilidad del modelo estadístico resultante. LASSO implementa una penalización L1, la cual tiene un doble efecto: reduce algunos coeficientes a cero, eliminando efectivamente esas variables del modelo, y conserva aquellos coeficientes que contribuyen significativamente al poder predictivo del modelo. Esta capacidad de selección crítica de características hace que LASSO sea especialmente valioso no solo para realizar predicciones precisas, sino también para identificar las variables más influyentes dentro del conjunto de datos, facilitando así un análisis más enfocado y eficiente.

3.4 Modelos de aprendizaje automático para la clasificación

En este estudio, el proceso de clasificación se llevó a cabo utilizando tres métodos: Random Forest, Regresión Logística y K-Vecinos Más Cercanos (KNN). Cada uno de estos métodos ha sido seleccionado por sus características únicas y su eficacia comprobada en diferentes tipos de datos y problemas de clasificación. Random Forest: Este método es un ensamble de árboles de decisión que opera mediante la creación de múltiples árboles durante el proceso de entrenamiento y la toma de decisiones basada en la mayoría de votos de estos árboles.

Regresión Logística: Es un modelo de clasificación lineal que se utiliza para predecir la probabilidad de una variable categórica binaria. Basado en la función logística, transforma su salida utilizando una función logit para devolver un valor de probabilidad que se sitúa entre 0 y 1.

K-Vecinos Más Cercanos (KNN): KNN es un algoritmo no paramétrico que clasifica cada punto de datos basándose en cómo están etiquetados los puntos más cercanos en el espacio de características. La principal fortaleza de KNN es su simplicidad y efectividad, especialmente en conjuntos de datos donde las relaciones entre las características son complejas y no lineales.

4 Experimentos y resultados

4.1 Conjunto de datos

Las imágenes de rayos X de rodilla que se utilizaron en nuestro estudio, se recopilaron durante un campamento de Densidad Mineral Ósea (DMO) organizado en el Hospital Unani y Panchkarma, Srinagar, India, y sus sucursales del 21 al 31 de diciembre de 2019. El campamento estuvo abierto para participantes de todos los grupos de edad y géneros de diversas regiones de Cachemira, India. El conjunto de datos incluye imágenes de rayos X y factores clínicos asociados a la osteoporosis. Tras obtener el consentimiento escrito, la DMO se midió con el sistema QUS Sunlight Omnisense 7000S, y posteriormente, los participantes que accedieron se sometieron a una radiografía de rodilla. De los 932 participantes en la prueba de DMO, 240 aceptaron la radiografía, resultando en 37 con DMO normal, 154 osteopénicos y 49 osteoporóticos. El conjunto de datos está



Fig. 2. Imágenes de muestra de la base de datos de las tres clases

disponible en la plataforma Mendeley [7]. Las muestras de radiografías de rodilla de clases normales, osteopénicas y osteoporóticas se muestran en la Figura 2.

4.2 Procesamiento de imágenes

Se aplicó de manera combinada las técnicas mencionadas previamente al conjunto de datos. Se probaron las siguientes combinaciones en la imagen:

- Ecualización de histograma adaptativo con contraste limitado (CLAHE)
- CLAHE seguido con la reducción de ruido mediante filtro mediano (MF)
- CLAHE seguido de suavizado utilizando operadores morfológicos (MO)
- CLAHE seguido de la técnica de reducción de ruido, basado en la transformada de coseno discreta (DCT).
- CLAHE seguido de la técnica de reducción de ruido, basado en la transformada wavelet discreta (DWT).

En la tabla 2, se presentan los resultados obtenidos al aplicar las métricas de evaluación tras completar el procesamiento de las imágenes. Los resultados tras

Table 2. Resultados de métricas de evaluación

Técnica	MSE	PSNR	AMBE
CLAHE-MEDIANA	196.806	25.190	3.985
CLAHE-MO	546.358	20.756	3.851
CLAHE-DCT	195.311	25.223	3.556
CLAHE-DWT	206.954	24.972	3.880

aplicar el procesamiento y las métricas de evaluación para determinar la técnica más efectiva se detallan a continuación. Según la tabla 2, la combinación que proporcionó los mejores resultados fue la aplicación de CLAHE seguida DCT. La imagen resultante de este proceso, utilizando CLAHE y DCT, se visualiza en la figura 3.



Fig. 3. Resultados al aplicar el procesamiento a la imagen



Fig. 4. Imágen generada aplicando HOG

4.3 Extracción de características

Para la extracción de características se implementó el algoritmo HOG bajo los siguientes parámetros:

- Píxeles por celda: Este parámetro especifica el tamaño de las celdas en las que se divide la imagen para calcular los histogramas de gradientes. se estableció en (16, 16).
- Píxeles por bloque: Este parámetro determina el tamaño de los bloques en los que se agrupan las celdas vecinas para realizar la normalización. Se estableció en (1, 1), lo que significa que no se realizó agrupación de celdas y cada celda fue considerada individualmente.
- Orientaciones: Este parámetro define el número de orientaciones en las que se divide el rango completo de 360 grados. Se estableció en 9, lo que significa que se calcularon los histogramas de gradientes en 9 direcciones diferentes.

Una vez completado el proceso, se generó un vector de características representativo que captura la información de las orientaciones de los gradientes presentes en la imagen (Figura 4), resultando en un vector compuesto por 36,864 características.

4.4 Selección de características

El método HOG genera un vector de características con una dimensión grande para la extracción eficiente de características. Para minimizar la redundancia de datos, reducir el tiempo de entrenamiento y mejorar el rendimiento del modelo, se implementaron dos técnicas de selección de características. Esto permitió identificar y retener solo las características más representativas.

La primera técnica implementada en nuestro estudio fue el análisis ANOVA, utilizando específicamente un F-test para identificar y seleccionar las características más relevantes de nuestro conjunto de datos. Optamos por seleccionar únicamente las 100 características que demostraron tener la relación más significativa con la variable objetivo, basándonos en las diferencias estadísticamente significativas entre las medias de los grupos. Esta selección estratégica permite centrarse en los atributos que más influyen en la variable de interés, optimizando así el rendimiento del análisis posterior.

La segunda técnica que implementamos fue LASSO, en particular la variante LassoCV, que incorpora validación cruzada para determinar el valor óptimo del parámetro de penalización, conocido como alpha. Se optó por emplear una validación cruzada de 10 iteraciones para asegurar la robustez y la precisión de la selección de parámetros. Tras la aplicación de esta técnica, se identificó y se seleccionaron 18 características del conjunto de datos, lo que nos permitió enfocarnos en los atributos más influyentes para el análisis posterior (Tabla 3).

Table 3. Técnicas de selección de características

Tipo	Técnica	Características	Caract. seleccionadas
Filtrado	ANOVA-F-test	36,864	100
Embebido	LASSO-LassoCV	36,864	18

4.5 Resultados de clasificación

Para nuestros modelos, se utilizó el 80% de los datos para entrenamiento y el 20% restante para validación. A continuación, se detallan los parámetros configurados para cada uno de nuestros modelos:

- Regresión logística: Se utilizó un límite de 1000 iteraciones para la convergencia.
- Random forest: Se utilizó 100 árboles en el ensamble.
- KNN: Se consideraron 10 vecinos más cercanos

La precisión de los modelos que utilizaron la técnica de reducción de características LASSO varió según el método de clasificación empleado: la regresión logística alcanzó un 75%, el método de Random Forest obtuvo un 68% y el

Table 4. Reporte de clasificación

Modelo	Clase	Precisión	Recall	F1-Score	Soporte
RL + LASSO					
	Normal	0.50	0.30	0.38	10
	Osteopenia	0.63	0.93	0.75	28
	Osteoporosis	1.00	1.00	1.00	10
RF + LASSO					
	Normal	0.67	0.20	0.31	10
	Osteopenia	0.60	0.86	0.71	28
	Osteoporosis	0.40	0.20	0.27	10
KNN + LASSO					
	Normal	0.25	0.10	0.14	10
	Osteopenia	0.62	0.93	0.74	28
	Osteoporosis	1.00	1.00	1.00	10
RL + ANOVA					
	Normal	0.29	0.20	0.24	10
	Osteopenia	0.63	0.79	0.70	28
	Osteoporosis	0.17	0.10	0.12	10
RF + ANOVA					
	Normal	0.29	0.20	0.24	10
	Osteopenia	0.63	0.79	0.70	28
	Osteoporosis	0.18	0.10	0.12	10
KNN + ANOVA					
	Normal	0.43	0.30	0.35	10
	Osteopenia	0.62	0.86	0.72	28
	Osteoporosis	0.00	0.00	0.00	10

algoritmo KNN registró un 65%. Utilizando la selección de características con ANOVA, la precisión que se obtuvo con regresión logística fue de 54%, el método de Random Forest obtuvo un 58% y el algoritmo KNN registró un 56%.

En la Tabla 4 se presentan los resultados de la clasificación obtenidos mediante tres modelos diferentes, los cuales emplearon técnicas de selección de características utilizando tanto ANOVA como LASSO.

Los modelos que utilizan LASSO tienden a mostrar una mejor precisión en general comparados con los que usan ANOVA, especialmente para las clases de osteopenia y osteoporosis. Por ejemplo, en la regresión logística con LASSO, la osteoporosis tiene un recall y precisión perfectos, lo que indica que LASSO puede ser más efectivo para identificar características relevantes en este contexto.

La clase Osteoporosis es clasificada con una precisión y recall de 1.00 con los modelos RL y KNN utilizando LASSO, esto quiere decir que estos modelos nos dieron resultados prometedores para esta clase. Por otro lado en la clase normal muestra un rendimiento más bajo en todos los clasificadores utilizando ANOVA Y LASSO. En general los modelos tienden a tener un rendimiento desigual en términos de precisión y recall. Para la Osteoporosis utilizando ANOVA, tanto la precisión como el recall son bajos en la regresión logística y Random Forest, lo que nos indica que nuestros modelos no logran capturar la complejidad de la clase.

5 Conclusiones

La aplicación de técnicas de selección de características, como ANOVA y LASSO, ha demostrado ser fundamental para reducir la dimensionalidad y optimizar el rendimiento de nuestros modelos predictivos. En particular, LASSO ha resultado ser especialmente efectivo, eliminando variables redundantes y mejorando la precisión en nuestro conjunto de datos específico.

A lo largo de este estudio, los modelos analizados presentaron variaciones significativas en su eficacia, destacando particularmente en la clasificación de condiciones de osteopenia y osteoporosis, comparativamente superior a la de condiciones normales. Esta observación nos indica la importancia de implementar estrategias de entrenamiento más equilibradas y técnicas de muestreo que reflejen de manera más precisa la distribución real de las condiciones clínicas. Para futuras investigaciones, sería bueno explorar otras técnicas de selección de características, incluyendo métodos como la eliminación recursiva de características y modelos basados en penalización. Además, la expansión del conjunto de datos con más muestras diversificadas podría incrementar sustancialmente la robustez y la generalización de los modelos.

6 Anexo: Implementación del algoritmo aplicando LASSO

```

1 def cargar_y_extraer_caracteristicas(rutas_carpetas,
   tama o_imagen=(1024, 1024), pixeles_por_celda=(16, 16),
   celdas_por_bloque=(1, 1), orientaciones=9):
2     caracteristicas = []
3     etiquetas = []
4     imagenes_hog = []
5     for etiqueta, ruta_carpetas in enumerate(rutas_carpetas):
6         for nombre_archivo in os.listdir(ruta_carpetas):
7             ruta_imagen = os.path.join(ruta_carpetas,
   nombre_archivo)
8             img = cv2.imread(ruta_imagen, cv2.IMREAD_COLOR)
9             if img is not None:
10                 img = cv2.resize(img, tama o_imagen)
11                 if img.ndim == 3:
12                     img = cv2.cvtColor(img, cv2.
   COLOR_BGR2GRAY)
13                     caracteristica_hog, imagen_hog =
   extraer_caracteristicas_hog(img, pixeles_por_celda,
   celdas_por_bloque, orientaciones)
14                     caracteristicas.append(caracteristica_hog)
15                     etiquetas.append(etiqueta)
16                     imagenes_hog.append(imagen_hog)
17     return np.array(caracteristicas), np.array(etiquetas),
   imagenes_hog
18
19 def extraer_caracteristicas_hog(imagen, pixeles_por_celda
   =(16, 16), celdas_por_bloque=(1, 1), orientaciones=9):
20     caracteristicas_hog, imagen_hog = feature.hog(imagen,
   orientaciones=orientaciones, pixeles_por_celda=
   pixeles_por_celda,
21
   celdas_por_bloque=celdas_por_bloque, block_norm='L2-Hys',
22                                     visualize=
   True, feature_vector=True)
23     return caracteristicas_hog, imagen_hog
24
25 # Rutas a las carpetas de im genes
26 rutas_carpetas = [
27     r"C:\Users\araro\Documents\OsteoporosisBD\DCT\normal",
28     r"C:\Users\araro\Documents\OsteoporosisBD\DCT\osteopenia"
29     ,
29     r"C:\Users\araro\Documents\OsteoporosisBD\DCT\
   osteoporosis"
30 ]
31
32 caracteristicas, etiquetas, imagenes_hog =
   cargar_y_extraer_caracteristicas_de_carpetas(
   rutas_carpetas)
33

```

```

34 X_entrenamiento, X_prueba, y_entrenamiento, y_prueba =
    train_test_split(caracteristicas, etiquetas, test_size
        =0.2, random_state=42)
35
36 # Escalar los datos para normalizarlos
37 escalador = StandardScaler()
38 X_entrenamiento_escalado = escalador.fit_transform(
    X_entrenamiento)
39 X_prueba_escalado = escalador.transform(X_prueba)
40
41 print(f"N mero total de caracter sticas antes de Lasso: {
    X_entrenamiento_escalado.shape[1]}")
42
43 # Aplicar Lasso para selecci n de caracter sticas
44 lasso = LassoCV(cv=10, random_state=42, max_iter=10000)
45 lasso.fit(X_entrenamiento_escalado, y_entrenamiento)
46
47 # Identificar las caracter sticas seleccionadas
48 coeficientes_importantes = np.where(lasso.coef_ != 0)[0]
49 print(f"Num de caracter sticas seleccionadas por Lasso: {len
    (coeficientes_importantes)}")
50
51 X_entrenamiento_lasso = X_entrenamiento_escalado[:,
    coeficientes_importantes]
52 X_prueba_lasso = X_prueba_escalado[:,
    coeficientes_importantes]
53
54 modelos = {
55     "Regresi n Log stica": LogisticRegression(max_iter
        =1000, random_state=42),
56     "Bosque Aleatorio": RandomForestClassifier(n_estimators
        =100, random_state=42),
57     "KNN": KNeighborsClassifier(n_neighbors=10)
58 }
59
60 for nombre, modelo in modelos.items():
61     modelo.fit(X_entrenamiento_lasso, y_entrenamiento)
62     predicciones = modelo.predict(X_prueba_lasso)
63     exactitud = accuracy_score(y_prueba, predicciones)
64     print(f"Rendimiento del modelo {nombre}:")
65     print("Exactitud:", exactitud)
66     print(classification_report(y_prueba, predicciones))
67     cm = confusion_matrix(y_prueba, predicciones)
68     plt.figure(figsize=(8, 6))
69     sns.heatmap(cm, annot=True, fmt='d', cmap='Blues',
        xticklabels=['Normal', 'Osteopenia', 'Osteoporosis'],
        yticklabels=['Normal', 'Osteopenia', 'Osteoporosis'])
70     plt.xlabel('Predicho')
71     plt.ylabel('Verdadero')
72     plt.title(f'Matriz de Confusi n para {nombre}')

```

```
73 plt.show()
```

Listing 1.1. Código para extracción y clasificación de características de imágenes utilizando LASSO

7 Anexo: Implementación del algoritmo aplicando ANOVA

```
1 def cargar_y_extraer_caracteristicas(rutas_carpetas,
   tama o_imagen=(1024, 1024), pixeles_por_celda=(16, 16),
   celdas_por_bloque=(1, 1), orientaciones=9):
2     caracteristicas = []
3     etiquetas = []
4     imagenes_hog = []
5     for etiqueta, ruta_carpetas in enumerate(rutas_carpetas):
6         for nombre_archivo in os.listdir(ruta_carpetas):
7             ruta_imagen = os.path.join(ruta_carpetas,
8                 nombre_archivo)
9             img = cv2.imread(ruta_imagen, cv2.IMREAD_COLOR)
10            if img is not None:
11                img = cv2.resize(img, tama o_imagen)
12                if img.ndim == 3:
13                    img = cv2.cvtColor(img, cv2.
14                        COLOR_BGR2GRAY)
15                    caracteristica_hog, imagen_hog =
16                        extraer_caracteristicas_hog(img, pixeles_por_celda,
17                            celdas_por_bloque, orientaciones)
18                    caracteristicas.append(caracteristica_hog)
19                    etiquetas.append(etiqueta)
20                    imagenes_hog.append(imagen_hog)
21            return np.array(caracteristicas), np.array(etiquetas),
22                imagenes_hog
23
24 def extraer_caracteristicas_hog(imagen, pixeles_por_celda
25     =(16, 16), celdas_por_bloque=(1, 1), orientaciones=9):
26     caracteristicas_hog, imagen_hog = feature.hog(imagen,
27         orientaciones=orientaciones, pixeles_por_celda=
28         pixeles_por_celda,
29
30         celdas_por_bloque=celdas_por_bloque, block_norm='L2-Hys',
31             visualize=
32             True, feature_vector=True)
33     return caracteristicas_hog, imagen_hog
34
35 rutas_carpetas = [
36     r"C:\Users\araro\Documents\OsteoporosisBD\DCT\normal",
37     r"C:\Users\araro\Documents\OsteoporosisBD\DCT\osteopenia"
```

```

28     r"C:\Users\araro\Documents\OsteoporosisBD\DC\
osteoporosis"
29 ]
30
31 características, etiquetas, imagenes_hog =
    cargar_y_extraer_caracteristicas_de_carpetas(
        rutas_carpetas)
32
33 X_entrenamiento, X_prueba, y_entrenamiento, y_prueba =
    train_test_split(características, etiquetas, test_size
        =0.2, random_state=42)
34
35 escalador = StandardScaler()
36 X_entrenamiento_escalado = escalador.fit_transform(
    X_entrenamiento)
37 X_prueba_escalado = escalador.transform(X_prueba)
38
39 # Aplicar F-test para seleccionar las 100 mejores
    características
40 selector = SelectKBest(f_classif, k=100)
41 X_entrenamiento_seleccionado = selector.fit_transform(
    X_entrenamiento_escalado, y_entrenamiento)
42 X_prueba_seleccionado = selector.transform(X_prueba_escalado)
43
44 modelos = {
45     "Regresión Logística": LogisticRegression(max_iter
        =1000, random_state=42),
46     "Bosque Aleatorio": RandomForestClassifier(n_estimators
        =100, random_state=42),
47     "KNN": KNeighborsClassifier(n_neighbors=5)
48 }
49
50 for nombre, modelo in modelos.items():
51     modelo.fit(X_entrenamiento_seleccionado, y_entrenamiento)
52     predicciones = modelo.predict(X_prueba_seleccionado)
53     exactitud = accuracy_score(y_prueba, predicciones)
54     print(f"Rendimiento del modelo {nombre}:")
55     print("Exactitud:", exactitud)
56     print(classification_report(y_prueba, predicciones))
57     cm = confusion_matrix(y_prueba, predicciones)
58     plt.figure(figsize=(8, 6))
59     sns.heatmap(cm, annot=True, fmt="d", cmap="Blues",
        xticklabels=['Normal', 'Osteopenia', 'Osteoporosis'],
        yticklabels=['Normal', 'Osteopenia', 'Osteoporosis'])
60     plt.xlabel('Predicho')
61     plt.ylabel('Verdadero')
62     plt.title(f'Matriz de Confusión para {nombre}')
63     plt.show()

```

Listing 1.2. Código para cargar imágenes y extraer características

References

1. R. M. Ortega, A. I. Jiménez Ortega, R. M. Martínez García, E. Cuadrado-Soto, A. Aparicio, and A. M. López-Sobaler, “Nutrición en la prevención y el control de la osteoporosis,” *Nutrición Hospitalaria*, vol. 37, no. SPE2, pp. 63–66, 2020.
2. J. Paccou and B. Cortet, “Osteoporosis: generalidades, estrategia diagnóstica,” *EMC-Podología*, vol. 25, no. 2, pp. 1–9, 2023.
3. P. Pisani, M. D. Renna, F. Conversano, E. Casciaro, M. Muratore, E. Quarta, M. Di Paola, and S. Casciaro, “Screening and early diagnosis of osteoporosis through x-ray and ultrasound based techniques,” *World journal of radiology*, vol. 5, no. 11, p. 398, 2013.
4. J. Massatith, N. Boonnam, and R. Hama, “Osteoporosis prognosis through machine learning analysis of x-ray films,” in *2023 27th International Computer Science and Engineering Conference (ICSEC)*. IEEE, 2023, pp. 104–109.
5. U. B. Abubakar, M. M. Boukar, and S. Adeshina, “Evaluation of parameter fine-tuning with transfer learning for osteoporosis classification in knee radiograph,” *International Journal of Advanced Computer Science and Applications*, vol. 13, no. 8, 2022.
6. I. M. Wani and S. Arora, “Osteoporosis diagnosis in knee x-rays by transfer learning based on convolution neural network,” *Multimedia Tools and Applications*, vol. 82, no. 9, pp. 14 193–14 217, 2023.
7. —, “A knee x-ray database for osteoporosis detection,” pp. 1–5, 2021.