

Customer Transactions: Análisis estadístico

Araceli Roque Hernández¹

Instituto Nacional de Astrofísica Óptica y Electrónica, Luis Enrique Erro 1,
Tonantzintla, Puebla, Mexico

Abstract. Se realiza el análisis de una base de datos obtenida de Kaggle "Customer Transactions" utilizando una combinación de estadística descriptiva e inferencial para lograr una comprensión detallada de la distribución de los datos. Además, se aplican pruebas estadísticas con el objetivo de validar o refutar diversas hipótesis, contribuyendo así a un análisis más robusto y fundamentado.

Keywords: Shopping behaviour · Transactions · Statistical analysis · Inference statistics

1 Introducción

De acuerdo con la finalidad del estudio y mediante el análisis e interpretación de datos, la estadística nos permite inferir de manera objetiva información que sustente la toma de decisiones o el entendimiento de fenómenos complejos tanto social como naturales.

En especial, la estadística descriptiva, mediante el uso de la distribución de frecuencias, medidas de tendencia central y medidas de dispersión nos permite analizar aspectos relevantes de un conjunto de datos. Por otro lado, la estadística inferencial apoyada en la estadística descriptiva y pruebas estadísticas (X^2 , regresiones, T-student, ANOVA, entre otros), nos permite llevar a cabo conclusiones sobre el conjunto de datos que nos permitan tomar decisiones, inferir nuevo conocimiento y explicar fenómenos sociales y naturales.

En este trabajo, se estudió un conjunto de datos sobre transacciones de clientes, analizando a este conjunto mediante la estadística descriptiva y comprobando aseveraciones que surgían a partir de la observación de los datos.

2 Desarrollo

En esta sección se describen los procedimientos adoptados durante la implementación y experimentación de la base de datos seleccionada.

2.1 Base de datos

Se empleó la base de datos "Customer Transactions" de la plataforma Kaggle, debido a su completitud en términos de cantidad de datos, número de atributos y

número de clases, lo que facilita su manipulación; se incluye 1 variable implícita (número de transacciones) y 8 variables explícitas, de las cuales 2 se considerarán clases (género y categoría). Dichos atributos se describen a continuación:

- **Customer ID:** Identificador único de cada cliente.
- **Name:** Nombre del cliente.
- **Surname:** Apellido del cliente.
- **Gender:** Género del cliente.
- **Birthdate:** Fecha de nacimiento del cliente.
- **Transaction Amount:** Monto de la transacción.
- **Date:** Fecha de la transacción.
- **Merchant:** Nombre del comercio donde se realizó la transacción.
- **Category:** Categoría de la transacción.

2.2 Análisis descriptivo

La estadística descriptiva, mediante el uso de la distribución de frecuencias, medidas de tendencia central y medidas de dispersión nos permite analizar aspectos relevantes de un conjunto de datos.

Para el análisis descriptivo se hizo uso de las siguientes métricas:

- **Media:** Promedio del monto de transacción
- **Mediana, 25, 75:** Monto por debajo el cual se encuentran el 50, 25 y 75 por ciento de las transacciones, respectivamente.
- **Percentiles:**
- **Desviación estándar:** Variación o dispersión del conjunto de transacciones.
- **Mínimo:** Monto mínimo de las transacciones
- **Máximo:** Monto máximo de las transacciones
- **Gráficas de distribución:** Correspondientes a los montos de las transacciones, transacciones realizadas por cada género, transacciones realizadas de cada categoría, y compras realizadas por mes.

2.3 Análisis inferencial

La estadística inferencial apoyada en la estadística descriptiva y pruebas estadísticas (X^2 , regresiones, T-student y ANOVA), nos permite llevar a cabo conclusiones sobre el conjunto de datos que nos permitan tomar decisiones, inferir nuevo conocimiento y explicar fenómenos sociales y naturales.

Pruebas estadísticas Se comienza por realizar un análisis exploratorio sobre la base de datos para conocer si es posible llevar a cabo el experimento deseado.

Observando el contenido de la base de datos y considerando la estadística descriptiva presentada anteriormente, se pueden identificar seis variables de estudio: Género, Monto de transacción, Cumpleaños, Año, Mes y Categoría. Y una variable implícita de estudio: Número de transacciones.

Correlaciones De existir una correlación entre las variables, es posible continuar con pruebas de regresión que permitan explicar cuestiones con más profundas sobre las relaciones que existen entre las variables. Los tipos de correlación son:

1. **Relación positiva:** Ambas variables incrementan o decrecen juntas
2. **Relación negativa:** Una variable incrementa y la otra decrece

Así mismo, se utilizan los siguientes casos para describir las correlaciones:

- **Fuerte:** -1 a -0.5 y 1 a 0.5
- **Moderada:** -0.5 a -0.3 y 0.5 a 0.3
- **Debil:** -0.3 a -0.1 y 0.3 a 0.1
- **Nula:** -0.1 a 0 y 0 a 0.1

Pruebas paramétricas y no paramétricas La prueba paramétrica necesita cumplir con los supuestos de normalidad para llevar a cabo el estudio de los datos:

- Distribución normal
- Independencia de las muestras
- Varianza constante

De no cumplir con los supuestos, se deberá optar por una prueba no paramétrica.

Hipótesis Para el análisis inferencial se postularon las siguientes hipótesis:

1. ¿El total de transacciones que realiza una persona son invariantes o muy semejantes mensualmente?
Nula: El total de transacciones realizadas por una persona no varía significativamente ni se mantiene constante mensualmente
Alternativa: El total de transacciones realizadas por una persona varía o se mantiene constante mensualmente
2. ¿El cumpleaños de una persona aumenta el total de transacciones que realiza ese día?
Nula: El cumpleaños de una persona no tiene relación con las transacciones que genera
Alternativa: El cumpleaños de una persona tiene relación con las transacciones que genera
3. ¿El gasto mensual es significativamente distinto para cada género?
Nula: No hay diferencia significativa en el gasto mensual entre géneros.
Alternativa: Existe una diferencia significativa en el gasto mensual
4. ¿La edad de los clientes influye en el monto de la transacción?
Nula: La edad no tiene efecto en el monto de las transacciones
Alternativa: La edad de los clientes tiene un efecto significativo en el monto de las compras

Además, se llevó a cabo un análisis de independencia para: Cantidad de transacciones que se realizaron por género en cada categoría. Monto de transacción respecto a la categoría de compra

3 Resultados

3.1 Análisis descriptivo

A partir del análisis descriptivo se obtuvieron los siguientes resultados para las métricas mencionadas en la sección 2.2.

- **Total transacciones registradas:** 50,000 transacciones
Conocer el total de transacciones registradas nos permite dimensionar el tamaño de la muestra que representa la base de datos y contextualizar el análisis.
- **Mínimo:** 5.01 dolares y **Máximo:** 2,999.88 dolares
Los montos mínimos y máximos nos permiten ver la polarización de los valores que pueden tomar las transacciones; esto es, pues en algunas categorías se pueden adquirir objetos de bajo costo (como en Cosmetic o Clothing), y en otras con costos altos (como en el caso de Electronics o Travel).
- **25:** 79.01 dolares, **Mediana (50):** 182.20 dolares y **75:** 470.52 dolares Como se puede observar, a pesar de existir compras de casi 3000 dólares, la mitad de transacciones incluidas en la base de datos fueron por debajo de 200 dólares y el 75 porciento se mantuvieron por debajo de los 500 dólares.
- **Media:** 442.12 dolares
En contraste con el análisis anterior, podemos observar que la media no coincide con la mediana, al encontrarse el valor promedio ubicado dentro de la mitad inferior de transacciones realizadas. Esto nos dice que a pesar de existir transacciones de alta denominación, la presencia mayoritaria de compras de menor valor mantiene el promedio en un nivel bajo.
- **Desviación estándar:** 632.67 Como podemos observar la desviación estándar es relativamente alta, por lo cual podemos deducir que los montos de las transacciones varían ampliamente en comparación con el promedio; Los montos de las transacciones son más dispersos, abarcando un rango más amplio de valores reflejando una diversidad considerable en los datos.

Distribución por género Se contabilizaron las compras realizadas por cada uno de los géneros para contrastar sus niveles de consumo. Esto, aplicado a un análisis de mercado, permite ver el comportamiento de los consumidores y determinar el perfil del usuario objetivo. El total de transacciones realizadas por cada género se muestra en la Fig. 1; se registraron 22713 transacciones realizadas por mujeres, 22240 hechas por hombres y 5047 cuyo género no viene especificado en la base de datos.

Con esto, a pesar de que la cantidad de transacciones no son tan distantes para los distintos sexos, se puede decir estrictamente que las mujeres consumen en mayor medida que los hombres.




Fig. 1: Número de transacciones por género.

Distribución por categorías Se realizó un conteo del número de transacciones realizadas correspondientes a cada una de las categorías disponibles; con esto, se puede observar en qué departamento consumen más comunmente los usuarios (ver Fig. 2). Para la categoría de Restaurants se tienen 8413 transacciones, para Market 8382, para Travel 8377, para Electronics 8324, para Clothing 8261 y para Cosmetics 8243.




Fig. 2: Número de transacciones por categoría.

Del mismo modo se realizó la suma de los montos de las transacciones de cada categoria, para conocer las cantidades invertidas en cada una por los clientes (ver Fig. 3). El monto total para la categoría Restaurant es de 464488.60 dólares, para Cosmetic 464488.60, para Clothing 1319342.47, para Market 2151134.42, para Electronics 4394092.10 y para Travel 12900231.94.

A pesar de que la cantidad de transacciones se mantuvo relativamente equivalente para todas las categorías, la suma de los montos invertidos en cada una varía en gran medida, alcanzando más del doble entre la categoría de Electrónicos y la




Fig. 3: Suma de monto de transacciones por categoría.

de Travel, correspondientes a las categorías con mayor inversión. En contraste, se puede observar que aunque Cosmetics es la categoría con mayor número de transacciones, la de menor suma de montos es Restaurants, que a su vez es la categoría con mayor número de transacciones, aunque Travel es la correspondiente a la mayor suma de montos de las transacciones.

Distribución por mes Con el fin de encontrar el mes con mayor actividad, se calculó la cantidad de transacciones realizadas en cada uno; esto puede ayudar a establecer las temporadas de ofertas, descuentos o promociones, o bien, predecir la mejor fecha para lanzar a la venta un producto. Para el mes de Enero la cantidad de transacciones es de 5444, Febrero 4854, Marzo 5456, Abril 5091, Mayo 5493, Junio 5258, Julio 5458, Agosto 5399, Septiembre 5153 y Octubre 2394. En la Fig. 4, se muestra la grafica obtenida.

De la gráfica anterior se observa que el mes con mayor número de transacciones fue el mes 05, Mayo. En la Fig. 5 se muestra la cantidad de transacciones de cada categoría realizadas durante este mes.

3.2 Análisis inferencial

Los resultados obtenidos de las pruebas para el análisis inferencial descrito en la sección 2.3 se muestran a continuación.

Análisis de variables categóricas

- **Cantidad de transacciones que se realizaron por género en cada categoría:** Se exploró la relación entre las variables categóricas 'Gender' (género) y 'Category' (categoría). Los resultados de este análisis se resumen en la tabla de contingencia como se muestra en la Fig. 6, la cual proporciona




Fig. 4: Transacciones por mes.




Fig. 5: Transacciones del mes de Mayo, por categoría

una visión detallada de la distribución de observaciones para cada combinación de género y categoría.

Posteriormente se realizó un test de chi-cuadrado para evaluar la independencia entre la variable Gender y category, obteniendo un valor estadístico Chi-cuadrado de 7.91489 y Valor p: 0.160988, utilizando un nivel de significancia de 0.05, basándose en los resultados de la prueba, no se encontró evidencia estadística significativa para afirmar que hay una asociación entre Gender y Category.

- **Monto de la transacción y categoría de compra:** Para evaluar si hay diferencias significativas en los montos de transacción entre las diferentes categorías se realizó un análisis de varianza (ANOVA), obteniendo los resultados mostrados en la Fig. 7




Fig. 6: Tabla de contingencia




Fig. 7: Distribución del monto de transacción, por categoría

Los resultados obtenidos con la prueba estadística ANOVA se obtuvo un valor Estadístico F de 19968.81 y un valor p 0.0 utilizando un nivel de significancia de 0.05, lo cuál indican que hay diferencias significativas entre las categorías en términos de montos de transacción.

En cuánto a las hipótesis planteadas se obtuvieron los siguientes resultados.

- **Hipótesis 1:** Para comprobar si el total de transacciones que realiza una persona son invariantes o muy semejantes mensualmente, en primer lugar se contabilizó cuántas transacciones hizo cada usuario (ver Fig. 8). Sin embargo, la base de datos solo describe una transacción por persona, es decir, todas las transacciones fueron realizadas por personas con ID diferentes, por lo tanto, no es posible establecer un estudio más profundo, descartando la hipótesis.

Fig. 8: Número de transacciones por usuario.

- ```
if fecha[5:] == persona[5:]:
 print("Coincidencia: ", fecha, cumple[i], np_datos[j][i])
 personas_cumple.append(persona[5:])
```

– **Hipótesis 3:** Partiendo de la descripción de los datos en las gráficas Fig. 4 y 6. Se observó que pese a la variación mensuales en las transacciones, la distribución de éstas transacciones sobre las categorías se mantenían muy similares entre el genero masculino y femenino. No obstante, en la categoria cosmeticos y viajes, se lograba percibir una variación más pronunciada de transacciones, que visto de otro modo tambien representan gastos. Entonces, sin ningún sesgo por el genero, el costo que representan los cosmeticos y los viajes provocó que nos preguntáramos si podía existir un gasto significativo mensualmente en alguno de los generos, formulando de está forma la hipótesis.

Por lo tanto, primero se llevo a cabo la selección aleatoria de 3 muestras con 5 repeticiones de gastos femeninos y masculinos por mes, recolectando como resultado 30 muestras y 150 repeticiones para todo el experimento. Luego, se empleo un diagrama de histogramas para interpretar a priori la distribución normal de los datos y continuar empleando una prueba estadística paramétrica. Sin embargo, se observó que los datos presentan una distribución asimétrica positiva, asintótica hacia la izquierda y leptocurtica. Entonces, se rechazó el uso de pruebas estadísticas paramétricas y se optó por emplear una prueba no paramétrica Mann-Whitney para comparar las dos distribuciones con intervalo de confianza del 95 por ciento. En este sentido, como hipótesis nula de la prueba estadística se estableció que "Los gastos son iguales sin importar el género." y como hipótesis alterna que "Los gastos son diferentes para uno de los géneros." Finalmente, con un  $P=0.34$  mayo a

0.05 se concluye que no hay significancia estadística, y por lo tanto, se rechaza la hipótesis alterna y se acepta la hipótesis nula: Los gastos son iguales sin importar el género (ver Fig. 10).




Fig. 10: Distribución de gastos por genero

- **Hipótesis 4:** Para el análisis primero se examinaron las estadísticas descriptivas de la variable Edad y Transaction Amount, se calculo la edad de los usuarios.

Para calcular la correlación entre la edad y el monto de las transacciones se utilizo el coeficiente de correlación de Pearson para medir la relación estadística entre las dos variables. Esta prueba proporciona un valor de correlación y un valor p. que indica la significancia estadística de la relación. Se formulo la hipótesis nula y alternativa sobre la influencia de la edad en el monto de transacciones y se utilizo el valor p. para decidir si rechazar o no la hipótesis nula. Fig. 11) Se realizo un modelo de regresion de lineal para comprender mejor la relación cuantitativa entre la edad y el monto de las transacciones. Los resultados obtenidos se muestran en las tablas 1, 2 y 3.

La correlación de Pearson correspondiente a la hipótesis 4 es de 0.003167004 entre la edad y el monto de transacciones, lo cual significa que no hay una relación lineal fuerte entre estas dos variables. El valor p es de 0.478853486 utilizando un umbral de significancia de 0.05, por lo cuál no hay suficiente evidencia para rechazar la hipótesis nula.

Respecto a los resultados de la regresión lineal (OLS), el coeficiente para la edad es 0.1189, por lo cuál cada año adicional de edad, el monto de transacción aumenta en promedio 0.1189 unidades.

Con esto, se observa que la edad no muestra un efecto significativo en el monto de las transacciones

| Dep. Variable   | Transaction Amount | R-squared         | Valores     |
|-----------------|--------------------|-------------------|-------------|
| Model           | OLS                | adj. R-squared    | 0.000       |
| Method          | Least squares      | F-statistic       | -0.000      |
| Date            | Sat 25 Nov 2023    | Prob(F-statistic) | 0.5015      |
| Time            | 18:41:45           | Log-likelihood    | 0.479       |
| No observations | 50000              | AIC               | -3.9336e+05 |
| Df Residuals    | 49998              | BIC               | 7.867e+05   |
| Df Model        | 1                  |                   | 7.868e+05   |
| Covariance type | nonrobust          |                   |             |

Table 1: OLS Regression Results

|       | COEF     | STD ERR | T      | P< t  | [0.025  | 0.975]  |
|-------|----------|---------|--------|-------|---------|---------|
| const | 436.5791 | 8.318   | 52.487 | 0.000 | 420.276 | 452.882 |
| Edad  | 0.1189   | 0.168   | 0.708  | 0.479 | -0.210  | 0.448   |

Table 2: OLS Regression results

|               |           |                  |           |
|---------------|-----------|------------------|-----------|
| Omnibus       | 22526.401 | Durbin-watson    | 1.992     |
| Prob(Omnibus) | 0.000     | Jarque-Bera (JB) | 91626.525 |
| Skew          | 2.307     | Prob (JB)        | 0.00      |
| Kurtosis      | 7.764     | Cond. No         | 146.      |

Table 3: OLS Regression results




Fig. 11: Relación entre edad y monto de transacciones.

## 4 Conclusiones

Los datos a priori presumían conclusiones obvias a la vista de los gráficos. Sin embargo, muchas de estas conjeturas aparentemente obvias resultaron ser todo lo contrario.

Mostrándonos en este proceso la relevancia de las pruebas estadísticas y el sesgo que puede suceder si se utiliza únicamente estadística descriptiva para llevar a cabo conclusiones sobre los datos.

En el área de ventas, es importante realizar este tipo de análisis estadísticos pues pueden ayudar a identificar el comportamiento de los consumidores y con ello proponer estrategias de mercadeo. Es importante mencionar que los resultados obtenidos en este estudio pueden estar sesgados por la muestra seleccionada por la base de datos (lugar y fecha del estudio, nivel socioeconómico de los participantes, etc), por lo que las conclusiones obtenidas puedan no ser equivalentes para otras demografías.

## References

1. bkcoban. (26-11-2023). Customer -Transactions. Kaggle. <https://www.kaggle.com/datasets/bkcoban/customer-transactions>.
2. Author, F., Author, S.: Title of a proceedings paper. In: Editor, F., Editor, S. (eds.) CONFERENCE 2016, LNCS, vol. 9999, pp. 1–13. Springer, Heidelberg (2016). <https://doi.org/10.1007/1234567890>
3. Author, F., Author, S., Author, T.: Book title. 2nd edn. Publisher, Location (1999)
4. Author, A.-B.: Contribution title. In: 9th International Proceedings on Proceedings, pp. 1–2. Publisher, Location (2010)
5. LNCS Homepage, <http://www.springer.com/lncs>. Last accessed 4 Oct 2017
6. Estadística descriptiva para ciencia de datos, <https://deepnote.com/@mazzaroli/Estadistica-Descriptiva-para-Ciencias-de-Datos-b8622ee2-5fb0-44f3-8791-96915665574e>.
7. Probabilidad y estadística con python, <https://relopezbriega.github.io/blog/2015/06/27/probabilidad-y-estadistica-con-python>.